



**CARACTERIZACIÓN ESTADÍSTICA DE LA DIVERSIDAD AVIAR EN EL  
PARQUE NACIONAL DE DOÑANA, MEDIANTE ANÁLISIS ECO ACÚSTICO**  
**MODALIDAD DEL TFG: CONVENCIONAL**

**CONVOCATORIA:** EXTRAORDINARIA JUNIO 2024  
**ALUMNO / A:** CLAUDIA REYERO BARDELÁS  
**TUTOR / A:** MARÍA DEL MAR ANGULO MARTINEZ  
**GRADO:** MATEMÁTICA COMPUTACIONAL



## **AGRADECIMIENTOS**

Mi motivación personal para participar en este proyecto proviene de mi visita al parque de Doñana hace seis años en la que pude apreciar la belleza e importancia biológica del lugar. Por ello, me gustaría agradecer a Javier García Algarra por darme la oportunidad de desarrollar mi trabajo como parte de un proyecto tan bonito e importante.

Sobre todo quiero agradecer a Mar Angulo por haberme ayudado durante todo el desarrollo del trabajo y por su apoyo y ganas.

También quiero dar las gracias a Irene Mendoza y al resto del equipo de Birdeep por haber confiado en mí y haberme ayudado con lo que he necesitado.

El proyecto BIRDeep se apoya en la logística de la ICTS-RBD y recibe financiación de la Agencia Estatal de Investigación (TED2021-129871A-I00).

Por último, gracias a Silvia, Álvaro y al resto de mi familia por su apoyo y paciencia.



## **Resumen**

Este Trabajo de Fin de Grado explica el desarrollo estadístico del uso de índices de diversidad acústica para obtener información sobre la diversidad aviar en el Parque Nacional de Doñana. Dichos índices se han aplicado a un conjunto de grabaciones de audio procedentes del Espacio Natural de Doñana. El objetivo del presente trabajo es entender las variaciones de los índices de en el tiempo y en el espacio, analizando su variabilidad en diferentes períodos del año y en los distintos hábitats existentes dentro del parque. Los resultados muestran que el comportamiento de cada índice varía según el hábitat en el que se recoge y según la época del año.

## **Abstract**

This Final Degree Project explains the statistical development of the use of acoustic diversity indices to obtain information on avian diversity in the Doñana National Park. These indices have been applied to a set of audio recordings from the Doñana Natural Space. The objective of this work is to understand the variations of the indices in time and space, analyzing their variability in different periods of the year and in the different habitats within the park. The results show that the behavior of each index varies depending on the habitat in which it is collected and according to the time of year.

# CONTENIDO

Resumen	4
Abstract	4
CONTENIDO	5
ÍNDICE DE FIGURAS	7
ÍNDICE DE TABLAS	8
1. INTRODUCCIÓN	10
1.1 Motivación y contexto	10
1.2 Planteamiento del problema	11
1.3 Objetivos del trabajo	12
1.3.1. Cálculo de índices acústicos	12
1.3.2 Estudio espacial de los índices	12
1.3.3 Estudio temporal de los índices	12
1.3.4 Método de trabajo	12
2. ESTADO DE LA CUESTIÓN	12
2.1 Marco teórico	13
2.1.1 Índices acústicos	13
2.1.2 Contrastes estadísticos	15
2.1.1.1 Contraste de Mann Whitney	15
2.1.3 Modelos lineales	16
2.1.3.1 ANOVA	16
2.1.3.2 Modelos de efectos mixtos	17
2.1.4 Análisis temporal	17
2.1.4.1 Proceso estocástico	17
2.1.4.2 Serie temporal	17
2.1.4.3 Contraste de Dickey Fuller	17
2.1.4.4 Autocorrelación: ACF y PACF	18
2.1.4.5 Modelos autorregresivos y de media móvil	18
2.1.4.6 Modelo lineal general	19
2.1.4.7 Bondad de ajuste: Criterio de información de Akaike	19
2.2 Trabajos relacionados	19
2.2.1 Predicting bird diversity through acoustic indices within the Atlantic Forest biodiversity hotspot	20
2.2.2 Acoustic indices as proxies for biodiversity: a Meta-analysis	21
3. ASPECTOS METODOLÓGICOS	22
3.1 Metodología	22
3.1.1 Muestreo aleatorio:	22
3.1.2 Diferencias ambientales	23
3.2 Tecnologías empleadas	23
4. DESARROLLO DEL TRABAJO	24
4.1 Estudio de estacionalidad temporal	24

4.2 Cálculo de índices acústicos	25
4.3 Estudio espacial de los índices acústicos	26
4.3.1 Resultados ANOVA	26
4.3.2 Contraste de Mann-Whitney	34
4.4 Estudio temporal de los índices acústicos	36
4.4.1 Estudio de factores con modelos mixtos	37
4.4.2 Modelización ARIMA	39
4.4.2.1 Análisis de estacionariedad	42
4.4.2.2 Obtención de modelos ARIMA	44
4.4.2.3 Validación de modelos ARIMA	45
5. DISCUSIONES	50
5.1 Líneas futuras	51
6. REFERENCIAS	52

## ÍNDICE DE FIGURAS

Figura 1: Mapa de las grabadoras en la Reserva Biológica de Doñana, asociadas a la infraestructura de la ICTS-RBD.	11
Figura 2: Resultados gráficos de modelo ANOVA sobre índice ADI	27
Figura 3: Resultados gráficos de modelo ANOVA sobre índice ACI	28
Figura 4: Resultados gráficos de modelo ANOVA sobre índice AEI	29
Figura 5: Resultados gráficos de modelo ANOVA sobre índice BIO	30
Figura 6: Resultados gráficos de modelo ANOVA sobre índice NDSI	31
Figura 7: Resultados gráficos de modelo ANOVA sobre índice H	32
Figura 8: Resultados gráficos de modelo ANOVA sobre índice Ht	33
Figura 9: Gráficos de las series temporales del índice BIO en vera y en matorral	40
Figura 10: Descomposición de la serie temporal del índice BIO en matorral	40
Figura 11: Descomposición de la serie temporal del índice BIO en vera	41
Figura 12: Gráficos de ACF y PACF de la serie temporal del índice BIO en matorral	43
Figura 13: Gráficos de ACF y PACF de la serie temporal del índice BIO en vera	43
Figura 14: Resultado de ACF de los residuos del modelo ARIMA en matorral	46
Figura 15: Distribución de los residuales del modelo ARIMA en matorral	47
Figura 16: Resultado de ACF de los residuos del modelo ARIMA en vera	48
Figura 17: Distribución de los residuales del modelo ARIMA en vera	49

## ÍNDICE DE TABLAS

Tabla 1: Descripción de los índices acústicos utilizados en el análisis	14
Tabla 2: Resultados del modelo ANOVA del índice ADI	26
Tabla 3: Resultados del modelo ANOVA del índice ACI	28
Tabla 4: Resultados del modelo ANOVA del índice AEI	29
Tabla 5: Resultados del modelo ANOVA del índice BIO	30
Tabla 6: Resultados del modelo ANOVA del índice NDSI	31
Tabla 7: Resultados del modelo ANOVA del índice H	32
Tabla 8: Resultados del modelo ANOVA del índice Ht	33
Tabla 9: Resultados de prueba de Mann-Whitney	35
Tabla 10: AIC de los tres modelos realizados sobre cada índice	37
Tabla 11: Modelo más significativo para el índice ADI	38
Tabla 12: Modelos más significativo para el índice AEI	38
Tabla 13: Modelo con mejor resultado para el índice BIO	39
Tabla 14: Resultado del test de Dickey-Fuller de la serie temporal del índice BIO en matorral	42
Tabla 15: Resultado del test de Dickey-Fuller de la serie temporal del índice BIO en vera	42
Tabla 16: Resultados del mejor modelo de ARIMA para matorral	44
Tabla 17: Resultado de aplicar auto arima a la serie temporal del índice BIO en matorral	44
Tabla 18: Resultados del mejor modelo de ARIMA para vera	45
Tabla 19: Resultado de aplicar auto arima a la serie temporal del índice BIO en matorral	45
Tabla 20: Resultado del contraste de significación de coeficientes en matorral	46
Tabla 21: Resultado del contraste Ljung-Box en los residuos del modelo en matorral	46
Tabla 22: Resultados del test de Shapiro-Wilk en el modelo ARIMA de matorral	47
Tabla 23: Resultado del contraste de significación de coeficientes en vera	48
Tabla 24: Resultado del contraste Ljung-Box en los residuos del modelo en vera	48
Tabla 25: Resultados del test de Shapiro-Wilk en el modelo ARIMA de vera	49



## 1. INTRODUCCIÓN

### 1.1 Motivación y contexto

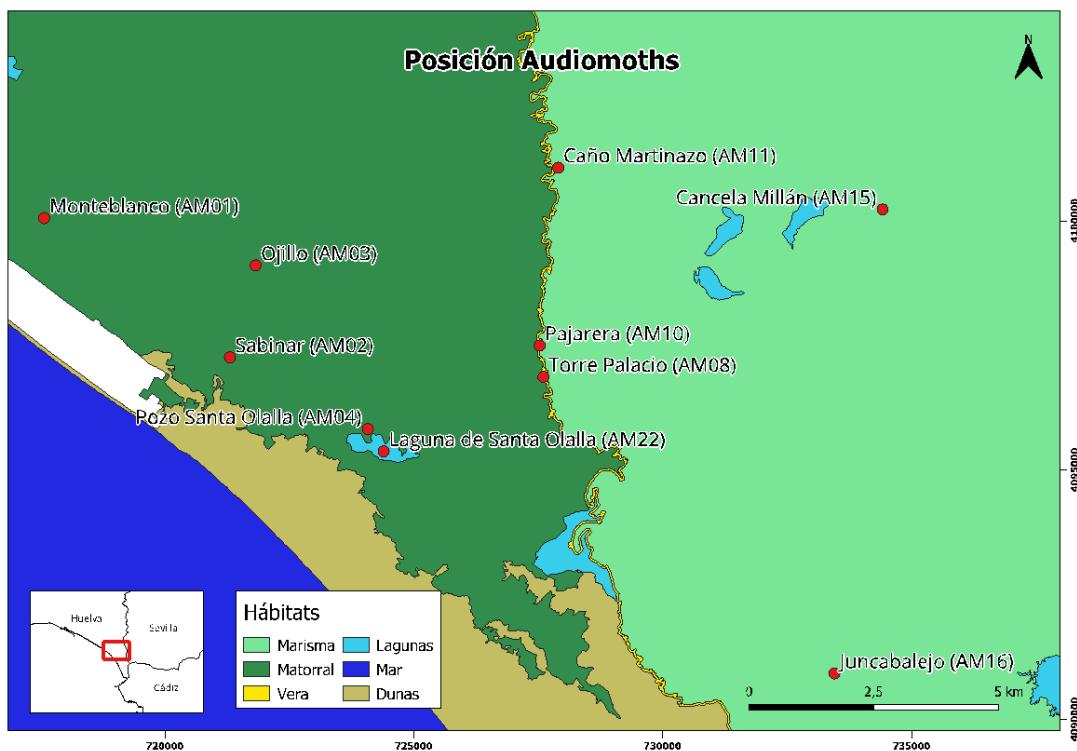
La monitorización acústica pasiva (PAM, por Passive Acoustic Monitoring) permite grabar de forma automática todos aquellos sonidos que sean de interés en grandes espacios naturales y durante largos períodos de tiempo. Un método como este genera una gran cantidad de audios que se pueden utilizar para realizar estudios ecoacústicos. La ecoacústica es un campo científico que se encuentra en pleno auge, y que estudia los sistemas acústicos desde la perspectiva ecológica (Vázquez, 2022). Entender las características ecoecológicas de una comunidad como su biofonía (sonidos causados por animales diferentes del ser humano) o su antropofonía (sonidos generados por las actividades humanas) permite estimar parámetros como los efectos de cambios medioambientales o el comportamiento de las especies. La ecoacústica es un elemento clave de la biodiversidad que define la complejidad sonora de un paisaje a través de dichas características ecoecológicas y puede cuantificarse mediante la variación de la intensidad y frecuencia del sonido en un tiempo y espacio determinado. (Barbaro et al., 2022) (Pijanowski et al., 2011) (Sueur & Farina, 2015) .

Los índices acústicos son valores obtenidos a partir de fórmulas matemáticas que permiten extraer y analizar información ecológica relevante a partir de audios grabados en distintos ambientes (Alcocer et al., 2022). Estos índices pueden reflejar patrones ecológicos de manera precisa, ya que afecta a sus resultados cualquier cambio que tenga un impacto en el paisaje sonoro que se esté estudiando (Bradfer-Lawrence et al., 2023).

Estos índices pueden trabajar con cualquier tipo de sonido recogido por una grabadora, incluyendo sonidos de animales como por ejemplo los cantos de aves. Las señales acústicas emitidas por las aves suelen ser específicas de cada especie, presentando pequeñas variaciones entre individuos de una misma especie y una alta variabilidad entre aquellas de diferentes especies. Estas características hacen posible utilizar los índices acústicos para identificar la diversidad aviar a través de grabaciones como las obtenidas de un proyecto PAM.

El Parque Nacional de Doñana es uno de los lugares más importantes de Europa con respecto a la diversidad de especies, ya que es considerado uno de los pocos humedales del sur de Europa. Gracias a sus características, es un importante sitio de invernada para numerosas especies de aves que migran desde los climas más fríos

durante el invierno. Estas especies migran a Doñana por sus grandes masas de agua y su abundancia en recursos. El proyecto BIRDeep busca estudiar la diversidad y fenología de las aves que habitan este parque.



**Figura 1:** Mapa de las grabadoras en la Reserva Biológica de Doñana, asociadas a la infraestructura de la ICTS-RBD.

Dentro del parque de Doñana, se encuentran cinco ecosistemas diferentes, la marisma, las dunas, el matorral, la vera y las lagunas. Esto hace que en él se produzca una combinación singular de aves procedentes tanto de Europa como de África, y es precisamente por esto por lo que se ha elegido este espacio natural para realizar un estudio sobre diversidad. Además, su alarmante estado de conservación provocado por distintos factores ambientales y de gestión, sugiere que es importante disponer de herramientas que permitan la monitorización en tiempo real del estado de todos sus ecosistemas.

## 1.2 Planteamiento del problema

Este Trabajo de Fin de Grado plantea analizar cómo la diversidad acústica varía espacio-temporalmente en el Parque Nacional de Doñana, utilizando para ello las grabaciones obtenidas por el proyecto BIRDeep . En este proyecto se propone un

estudio estadístico de este análisis ecoacústico con el objetivo de entender mejor la diversidad de los distintos ecosistemas contenidos dentro del parque.

### **1.3 Objetivos del trabajo**

#### **1.3.1. Cálculo de índices acústicos**

A pesar de que el muestreo original del proyecto BIRDeep incluye tres hábitats principales (matorral, vera y marisma), debido a aspectos logísticos, en este TFG solo se van a analizar los datos procedentes de los hábitats matorral y vera, con dos grabadoras cada uno (AM10 y AM11 para vera, AM1 y AM4 para matorral) recogidas en un periodo desde mayo de 2023 hasta diciembre de 2023.

#### **1.3.2 Estudio espacial de los índices**

Realizar análisis comparativos que permitan detectar diferencias en los índices acústicos en diferentes ecosistemas dentro del Parque de Doñana

#### **1.3.3 Estudio temporal de los índices**

Estudiar la serie temporal de los datos de cada uno de los índices acústicos obtenidos para comprobar su evolución y posibles cambios en diferentes períodos del año

#### **1.3.4 Método de trabajo**

Establecer un procedimiento de análisis de índices acústicos que permita un posterior análisis de la contribución de los mismos para explicar la diversidad de especies en el Parque Nacional de Doñana.

## **2. ESTADO DE LA CUESTIÓN**

La ecoacústica es una disciplina que está experimentando un rápido crecimiento gracias al desarrollo de tecnologías que ayudan a acelerar y profundizar en sus estudios. En el primer congreso internacional sobre ecología y acústica (que tuvo lugar en París en 2014) se nombró la ecoacústica como una nueva área de investigación y se lanzó la Sociedad Internacional de Ecoacústica (Alcocer et al., 2022).

Dentro de este ámbito, la relación entre la diversidad de las especies y la diversidad acústica es una teoría que no cuenta todavía con suficientes evidencias y que resulta complicado demostrar. Sin embargo, existen ya diversos estudios que intentan afirmar dicha conexión (Bradfer-Lawrence et al. 2020). Desde la creación de los índices acústicos se ha intentado demostrar sus capacidades como indicadores de la biodiversidad y se han realizado diversos estudios en diferentes ecosistemas, sin embargo, hasta la fecha los resultados obtenidos son ambiguos (Alcocer et al., 2022).

## 2.1 Marco teórico

### 2.1.1 Índices acústicos

Gracias a los proyectos PAM, existe la posibilidad de obtener grabaciones que componen un paisaje sonoro. El paisaje sonoro está definido como el conjunto de sonidos geofísicos, antropogénicos y biológicos de un paisaje que varían en el espacio y el tiempo (*Soundscape Ecology: The Science of Sound in the Landscape | BioScience | Oxford Academic*, s. f.).

Un índice de diversidad acústica es una medida cuantitativa de la heterogeneidad acústica de una muestra de sonido que se obtiene mediante un análisis temporal y espacial en el cual se cuenta la amplitud y frecuencia del paisaje sonoro. Este índice proporciona una medida de la biodiversidad del lugar donde se ha tomado la grabación sin la identificación de especies concretas (Andrews & Dick, 2021). Para calcular estos índices, se debe asumir que cuanto mayor sea la cantidad de especies en el ambiente, mayor será la energía acústica del paisaje sonoro.

La limitación principal que presenta el cálculo de estos índices es que no diferencian entre los sonidos que se escuchan, es por ello por lo que a la hora de aplicarlos se debe tener en cuenta que una alta cantidad de sonidos antropogénicos o geofónicos puede afectar a los resultados de los índices.

En la documentación recopilatoria más reciente, se han desarrollado más de 60 índices de los tipos  $\alpha$  (estudian la complejidad acústica de una sola grabación) y  $\beta$  (estudian la complejidad acústica de dos o más grabaciones) (Buxton et al., 2018). Este trabajo va a utilizar 7 de los índices  $\alpha$  que vienen descritos en la Tabla 1.

#### DESCRIPCIÓN DE ÍNDICES ACÚSTICOS

Índices acústicos	Descripción
Acoustic Complexity Index (ACI)	Produce una cuantificación directa y rápida de las vocalizaciones de las aves mediante el procesamiento de las intensidades registradas en un audio (Pieretti et al., 2011)
Bioacoustic Index (BIO)	Evalúa el nivel de sonido y la cantidad de bandas de frecuencia utilizadas (Boelman et al., 2007)
Acoustic Diversity Index (ADI)	Divide el espectrograma en bandas de frecuencia y calcula la señal de diversidad en cada una de ellas (Villanueva-Rivera et al., 2011)
Acoustic Evenness Index (AEI)	Mide la igualdad entre las distintas bandas de frecuencia de un audio (Villanueva-Rivera et al., 2011)
Temporal Entropy (Ht)	Utiliza en índice de uniformidad de Shannon aplicado a la amplitud de la serie temporal (Sueur et al., 2014)
Normalized Difference Soundscape Index (NDSI)	Estima el nivel de sonidos antropofónicos de un paisaje sonoro computando la relación entre los sonidos producidos por humanos y aquellos producidos por otros animales (Kasten et al., 2012)
Total Entropy Index (H)	Estima la dispersión de la energía acústica usando patrones de amplitud espectral y temporal (Sueur et al., 2014)

**Tabla 1:** Descripción de los índices acústicos utilizados en el análisis

Para interpretar los índices que se van a utilizar, en todos los casos un valor más alto del índice indica una mayor diversidad acústica, por lo que su interpretación más

eficaz se realiza comparando los valores obtenidos, bien en zonas diferentes en un mismo período de tiempo, bien en un mismo lugar a lo largo de un periodo de tiempo extendido.

### 2.1.2 Contrastes estadísticos

Los contrastes de hipótesis son una técnica estadística que se utiliza para probar la validez de una afirmación basándonos en la información recogida de una muestra. En cada contraste, la hipótesis estadística es la afirmación que deseamos contrastar. Además, un contraste tiene una hipótesis alternativa que es la que se acepta cuando la hipótesis nula o conservadora es rechazada.

Para determinar si se rechaza la hipótesis nula de un contraste o no, se utiliza el P-valor. El p-valor es un número entre 0 y 1 que representa el grado de compatibilidad de nuestros datos con la hipótesis nula (Fein et al., 2022). Esto quiere decir, que cuanto más se acerque este valor a 0, más incompatible será la muestra observada con la hipótesis nula. Para determinar a partir de qué P-valor se rechaza la hipótesis nula, se utiliza el nivel de significación o error de tipo I ( $\alpha$ ).

El error de tipo I es la probabilidad de rechazar la hipótesis nula siendo cierta, de manera que, si el p-valor es menor que el nivel de significación, entonces se rechazará la hipótesis nula (C. Fein et al., 2022).

Existen dos tipos de contrastes. Los paramétricos son aquellos en los que los datos provienen de alguna distribución de probabilidad y se utilizan para analizar valores que estén en un intervalo estimando el valor de un parámetro. Sin embargo, los contrastes no paramétricos son aquellos que analizan cuál es la distribución de los datos en vez de estimar el valor de uno de sus parámetros.

En este trabajo se van a aplicar contrastes no paramétricos, los cuales no asumen ningún tipo de distribución en los datos utilizados.

#### 2.1.1.1 Contraste de Mann Whitney

Este contraste examina la diferencia entre las medias o medianas de dos grupos independientes y no paramétricos (C. Fein et al., 2022). Se aplicará este contraste en las combinaciones de índices que permitirán entender la relación entre los valores de un mismo índice en distintas zonas comprendidas en un mismo hábitat.

Todas aquellas veces que se rechace la hipótesis nula, podremos decir que la combinación indicada contiene diferencias significativas entre sus medias y por tanto, ambas muestras no pertenecerán a la misma población.

### 2.1.3 Modelos lineales

#### 2.1.3.1 ANOVA

Los modelos ANOVA son un tipo de modelo lineal que se utiliza para conocer si hay relación entre el valor medio esperado de una característica y uno de sus factores (Vicente Vírseda et al., 2019). En este caso, se va a utilizar para ver si hay relación entregrupos e intra-grupo.

En el caso de la relación entre-grupos, se va a estudiar la relación entre la media de cada índice en matorral y la media global al igual que la media de cada índice en vera y la global. Además, para el estudio intra-grupo, se va a estudiar la relación entre la media de cada índice en una sola grabadora y la media global del hábitat en el que se encuentra dicha grabadora. Gracias a estos modelos ANOVA, se va a poder realizar un estudio espacial del comportamiento de cada índice.

Para aplicar ANOVA, se va a utilizar el análisis de varianza de un factor, en este caso se va a considerar la influencia del factor hábitat sobre los índices. Este análisis tiene como objetivo contrastar la homogeneidad simultánea de  $x$  poblaciones, en este caso, de dos poblaciones (una por cada hábitat). En el caso de que la hipótesis nula sea cierta, se diría que la diferencia entre los valores de cada hábitat se debe al azar y si no es cierta, indicaría que el hábitat es un factor significativo en el cálculo de los índices. Este modelo plantea la siguiente fórmula matemática:

$$\gamma_{ij} = \mu + \alpha_i + \mu_{ij}$$

Donde  $\mu_i = \mu + \alpha_i$  son las medias estimadas del modelo de manera que  $\mu$  será la media general y  $\alpha_i$  el efecto del factor en cada nivel (Vicente Vírseda et al., 2019).

Al realizar muchas pruebas en un modelo, aumenta el riesgo de cometer un error de tipo I. Es por ello por lo que una vez calculados los modelos, se va a aplicar la corrección de Benjamini-Hochberg que controla el descubrimiento falso (Thulin, 2021).

Para comprobar si el conjunto de datos cumple con la homocedasticidad requerida para crear un modelo ANOVA, se aplicará un contraste de Levène, el cual tiene como

hipótesis nula que las varianzas de todos los grupos son iguales. Es decir, si se rechaza la hipótesis nula de este contraste, se puede decir que al menos una varianza difiere y por lo tanto que hay heterocedasticidad en los datos utilizados.

#### *2.1.3.2 Modelos de efectos mixtos*

Los modelos lineales mixtos están compuestos por tres partes. La variable respuesta, las variables fijas y las variables aleatorias. Las variables fijas son datos de interés que no son aleatorios mientras que las variables aleatorias representan variables que hacen que los datos puedan estar correlacionados. Estas últimas no son de vital interés por su cuenta pero se deben incluir en el modelo para tener en cuenta las correlaciones entre mediciones (Thulin, 2021).

### **2.1.4 Análisis temporal**

#### *2.1.4.1 Proceso estocástico*

Un proceso estocástico consiste en una secuencia de variables aleatorias que están ordenadas y son equidistantes entre sí en el tiempo, referidas a una o varias características que pertenezcan a una unidad observable en distintos momentos. Su fórmula matemática sería:  $X_0, X_1, X_2 \dots$  donde  $X_t$  es una variable aleatoria .

#### *2.1.4.2 Serie temporal*

En el contexto de un proceso estocástico, una serie temporal se refiere a un periodo muestral de un proceso. Es decir, una serie temporal se considera una realización particular dentro de un proceso estocástico.

Una serie temporal será estacionaria cuando sus propiedades y métricas estadísticas se mantengan de forma estable a lo largo del tiempo sin presentar una tendencia. Si la serie obtenida es estacionaria, entonces se puede aplicar sobre ella un modelo ARMA. Sin embargo, si la serie no es estacionaria, entonces se utilizará un modelo ARIMA donde se introduce una integración para hacer que la serie sea estacionaria.

#### *2.1.4.3 Contraste de Dickey Fuller*

El contraste de Dickey Fuller es un contraste de integridad de una serie temporal. Este contraste realiza la estimación por mínimos cuadrados ordinarios y su hipótesis alternativa es la estacionalidad (Anchuelo, 1993). Es por ello, que va a servir para

complementar a ACF y PACF en el estudio de las series temporales. Gracias a este contraste se podrá elegir los audios que se van a utilizar en el cálculo de los índices acústicos.

#### *2.1.4.4 Autocorrelación: ACF y PACF*

La Función de Autocorrelación Simple (ACF) y la Función de Autocorrelación Parcial (PACF) permiten analizar de forma visual la relación entre dos variables separadas por  $k$  periodos. Ambas funciones devuelven un correlograma que permite interpretar la correlación entre distintos puntos de una serie temporal. La PACF, mide lo mismo con la diferencia de que no tiene en cuenta la relación entre las dos variables que está midiendo y todas aquellas que se encuentran en el periodo comprendido entre ambas (Yakubu & Saputra, 2022).

Gracias a estas dos funciones se puede interpretar con correlogramas para identificar si la serie de audios tomados cada 10 minutos y la de audios tomados cada media hora son estacionarias o no.

#### *2.1.4.5 Modelos autorregresivos y de media móvil*

Un modelo autorregresivo es aquel en el que suponemos que los datos de un periodo dependen de aquellos de los  $p$  periodos anteriores  $AR(p)$ . Este modelo utiliza el criterio de máxima verosimilitud el cual maximiza la probabilidad de obtener los datos predichos en el modelo.

Un modelo de media móvil  $MA(q)$  se da cuando las observaciones de un periodo  $t$  dependen de todas las observaciones anteriores.

El proceso  $ARMA(p,q)$  es la suma de un modelo autorregresivo y uno de medias móviles. Estos tres modelos están basados en modelos estocásticos donde la media y varianza son constantes y donde hay estacionalidad.

En aquellos casos donde la serie no sea estacionaria, se aplicará el modelo  $ARIMA(p,d,q)$ .

Los modelos ARIMA (modelo autorregresivo integrado de medias móviles) establecen la diferencia entre un valor de una serie temporal y el siguiente midiendo los saltos entre cada valor. Es decir, estima las diferencias entre los valores de una serie temporal:  $\omega_t = x_t - x_{(t-1)}$  diferencia entre el valor del periodo  $t$  y el anterior.

#### *2.1.4.6 Modelo lineal general*

Los modelos lineales generales se basan en tres supuestos principales. Los errores se distribuyen normalmente, la varianza es constante y las variables dependiente e independiente tienen una relación lineal. Sin embargo, en muchos de los casos este tipo de modelos se aplican sin que se cumplan todas estas características ya que siguen siendo útiles, aunque la muestra no se presente de dicha forma (Vicente Vírseda et al., 2019).

La fórmula de un modelo lineal de regresión es:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} \quad i = 1, 2, 3, \dots, n$$

En este trabajo se va a utilizar un modelo lineal para reflejar la significación que tiene el hábitat con respecto al valor del índice obtenido. Para ello, se creará un modelo donde la variable respuesta sea cada índice y la variable predictora sea el hábitat al que pertenece cada muestra. Teniendo estos modelos calculados, se van a comparar con modelos mixtos que van a incluir otros factores, es por ello por lo que se va a utilizar la métrica AIC para determinar qué modelo funciona mejor.

#### *2.1.4.7 Bondad de ajuste: Criterio de información de Akaike*

Para poder elegir qué modelo funciona mejor, se va a utilizar el Akaike Information Criterion (AIC) que es un método matemático que evalúa cómo de bien se adapta un modelo a los datos utilizados. Este criterio es muy utilizado para comparar diferentes posibles modelos y determinar cuál de ellos se adapta mejor a los datos. Según este criterio, el mejor modelo es aquel que explica una mayor cantidad de variación utilizando el menor número de variables independientes posible (Bevans, 2020). El criterio de aceptación será comparando el valor de AIC de cada modelo. Si el valor de uno de los modelos es por lo menos dos unidades menores que el de otro modelo, este primero será considerado como significativamente mejor modelo.

## **2.2 Trabajos relacionados**

El uso de los índices acústicos como predictores de la diversidad es un concepto muy reciente que, por tanto, carece de una gran cantidad de documentación válida hasta la fecha. Aquí se describen los dos trabajos que mejor resumen el estado actual del concepto.

## 2.2.1 Predicting bird diversity through acoustic indices within the Atlantic Forest biodiversity hotspot

El proyecto (Gaspar et al., 2023) muestra un estudio sobre la diversidad aviar en el la zona Cantareira-Mantiquera situada en el bosque Atlántico de Brasil. En este proyecto se calculó el valor de ocho índices acústicos dentro de los tres hábitats que componen esta zona, el bosque, el pantano y el pasto. Además de calcular estos índices, produjeron modelos lineales generales usando combinaciones de índices para compararlos con métricas del ambiente como la diversidad, la riqueza y la abundancia. Después utilizaron modelos lineales mixtos para calcular cómo de buenos eran estos índices en cada uno de los hábitats.

Este proyecto estudia cómo afectan los distintos hábitats al cálculo de varios índices acústicos aplicados a los sonidos de aves que se encuentran en estas zonas. El proyecto argumenta que los índices acústicos son testeados en aves mayoritariamente por su presencia en todos los ambientes y porque ofrecen una gran actividad acústica que es sensible a los cambios de entorno.

Los tres objetivos principales que presenta este trabajo son la contribución de los índices acústicos para explicar la riqueza, abundancia y diversidad, qué mejoras supone utilizar combinaciones de estos modelos y cuáles son las correlaciones entre ellos en distintos tipos de ambiente.

Tras haber calculado los índices acústicos y los modelos lineales, este trabajo utiliza modelos lineales de efectos mixtos (LMM) para contrastar la relación entre las métricas del ambiente y los índices acústicos considerando características del ambiente como factores aleatorios. Para calcular estos modelos utiliza bootstrapping para estandarizar el modelo y para detectar la posible multicolinealidad utiliza factores de inflación de varianza (VIF).

El trabajo concluye que el tipo de entorno del que se recogen los datos influye en el poder explicativo y por lo tanto indica qué índice va a funcionar mejor en cada entorno. Además, se insiste en que la combinación de dos índices da un resultado más completo de las métricas del ambiente que cualquier índice aplicado en solitario. Teniendo en cuenta las distintas métricas con la que se comparan los índices y sus niveles de correlación, se indica que los índices acústicos hacen una mejor labor de representar la actividad vocal de las aves que de representar su propia diversidad.

Por ello, vamos a replicar las combinaciones utilizadas en este trabajo en los ecosistemas de Doñana para comprobar si en un lugar de clima tan diferente al de Brasil, los modelos que funcionan mejor serán otros o los mismos.

### 2.2.2 Acoustic indices as proxies for biodiversity: a Meta-analysis

El trabajo de Alcocer et al. (2022) proporciona un meta-análisis de 34 estudios que han sido realizados hasta la fecha sobre índices acústicos y su relación con métricas de diversidad. En este artículo se comenta que en los primeros 10 años en los que se han desarrollado los índices acústicos, se han encontrado muchas contradicciones y disparidad en los resultados. Por ello procede a analizar los resultados de los estudios elegidos para intentar unificar sus conclusiones.

Este trabajo ofrece una visión global de la relación entre los índices y la diversidad, aunque reconoce las limitaciones de estos índices para detectar características sobre la diversidad considerándolos capaces de capturar cambios en métricas y una buena base para futuros desarrollos. Se ofrece una descripción detallada de los índices utilizados en estos estudios y de las métricas que se intenta predecir con ellos ya que, hasta la fecha, las descripciones de los índices no se encontraban unidas en un mismo lugar.

En primer lugar, el artículo explica sus criterios de inclusión para los estudios seleccionados que incluyen características como la cantidad de índices acústicos usados y el número de métricas de diversidad que trabaja. Una vez obtenidos los estudios definitivos, procede a realizar un meta-análisis tomando la Z de Fisher como variable respuesta. Los criterios incluidos finalmente son 7 índices (ACI, ADI, AEI, AR, BIO, H y NDSI), 4 métricas de diversidad (abundancia de especies, riqueza de especies, diversidad de especies y abundancia de sonidos), 2 tipos de entorno (terrestre y acuático), dos fuentes (acústica y no acústica) y 6 tipos de seres vivos (aves, peces, invertebrados, mamíferos, variado y anfibios).

Este trabajo también concluye que cada índice es más apropiado para cada una de las características y por lo tanto, la combinación de varios de ellos siempre da mejor resultado que su uso individual. También detecta que los índices tienen en general una mayor correlación con la abundancia de sonidos, por lo que, su mayor capacidad es detectar las diferencias en el número de señales grabadas, sin ser necesariamente un conjunto diverso de especies.

Otra de las conclusiones principales de este trabajo, es que señala el descuido en el análisis llevado a cabo en el campo de la ecoacústica que indica una falta de eficiencia

de estos índices. Se ha visto que uno de los errores principales que cometen el 40% de los estudios es interpretar las muestras como independientes si realmente serlo. Esto supone no tener en cuenta la autocorrelación entre los datos lo que lleva a una sobreestimación y por tanto a conclusiones erróneas.

También se concluye que al haber varios efectos ambientales que varían en distintos hábitats, esto afecta a la capacidad de los índices para extraer información de las grabadoras y que por lo tanto se debe tener en cuenta los resultados de cada índice dependiendo del ambiente en el que han sido calculados ya que sus resultados pueden variar drásticamente.

### 3. ASPECTOS METODOLÓGICOS

#### 3.1 Metodología

El desarrollo de este proyecto se ha llevado a cabo siguiendo las pautas marcadas por la metodología *SCRUM* (Trigás Gallego, 2012). El product owner del proyecto han sido los miembros del equipo de BIRDeep que trabajan desde Doñana y la U-Tad. Se han llevado a cabo reuniones bisemanales donde se ha discutido el estado del proyecto y se han marcado los objetivos para cada sprint.

##### 3.1.1 Muestreo aleatorio:

Para desarrollar el trabajo, se ha diseñado un sistema de PAM en el que las grabadoras automáticas de sonido se sitúan en los principales hábitats de Doñana. Dichas grabadoras recogen audios de un minuto tomados cada poco tiempo para poder analizar su contenido. El desarrollo de este proyecto se enmarca en una colaboración entre U-Tad y la Estación Biológica de Doñana (EBD), perteneciente al CSIC.

Para conseguir un muestreo aleatorio con el que calcular los valores de los índices. Se ha utilizado la técnica de bootstrapping (Gaspar et al., 2023) pero adaptada a la cantidad de datos obtenidos de las grabadoras en Doñana.

Se han obtenido grabaciones de 4 grabadoras situadas en dos hábitats diferentes. Todas estas grabaciones están divididas en 5 grupos temporales correspondientes a los períodos que hay entre cambio de pilas y tarjetas. Por ello, se ha aplicado

bootstrapping con reemplazamiento a cada uno de esos grupos obteniendo 400 audios de cada uno de ellos.

De esta manera, el resultado final será un conjunto de 2000 audios por cada grabadora que suponen una muestra aleatoria temporalmente.

### 3.1.2 Diferencias ambientales

La diversidad aviar varía dependiendo del lugar donde esté siendo analizada. Cada clima y ecosistema tiene especies diferentes con distintos comportamientos. Doñana es un lugar en el que conviven una gran variedad de especies debido a la presencia de varios hábitats distintos muy cerca los unos de los otros. El proyecto BIRDeep ha conseguido datos grabados desde mayo hasta diciembre de 2023. Estos son los datos que se van a utilizar en ese análisis estadístico.

Las grabadoras activas de las que se han obtenido datos consistentes son AM1, AM4, AM10 y AM11 que están localizadas según el mapa de la Figura 1. Se puede ver que dos de estas grabadoras están situadas en Matorral y las otras dos se encuentran en Vera, que es el nombre local para designar el ecotono o frontera entre el matorral y la marisma. Esto nos va a permitir estudiar la diferencia de diversidad entre los dos hábitats y entre distintos puntos de un mismo hábitat.

## 3.2 **Tecnologías empleadas**

Todo el desarrollo estadístico se ha llevado a cabo utilizando RStudio (*R: The R Project for Statistical Computing*, s. f.). Además, se ha requerido la instalación de diversos paquetes para llevar a cabo las distintas partes.

El cálculo de los índices acústicos se ha realizado utilizando el paquete *soundecology* (1.3.3)(Pieretti et al., 2011) y el paquete *seewave* (2.2.3) (Sueur et al., s. f.). Para calcular las series temporales y el contraste de Dickey Fuller, se ha utilizado el paquete *tseries* (0.10-56).

Para el cálculo de elementos estadísticos como ACF, la correlación, los contrastes varios, los modelos ANOVA y los modelos lineales generales se ha utilizado el paquete *stats* (4.3.2)(*R: The R Stats Package*, s. f.).

Para calcular los modelos lineales mixtos se ha utilizado el paquete *lme4* (1.1-35.3)(Bates et al., 2024)

A la hora de construir los gráficos varios realizados para representar los resultados estadísticos, se ha utilizado el paquete de *ggplot2* (3.5.0)(*Create Elegant Data Visualisations Using the Grammar of Graphics*, s. f.).

El motivo por el que se ha utilizado R para el desarrollo de este producto es porque en el ámbito de la ecología, es la herramienta líder en la que mejor se han desarrollado las funciones que calculan los índices acústicos. Por lo que, para poder realizar comparaciones con otros trabajos del mismo tipo, se ha optado por utilizar las mismas herramientas y paquetes.

## 4. DESARROLLO DEL TRABAJO

### 4.1 Estudio de estacionalidad temporal

El desarrollo de este trabajo ha comenzado con la elección de los datos a utilizar. Para decidir qué conjunto de datos utilizar, se ha observado la estacionalidad de las grabaciones con 10 minutos de intervalo y aquellas con 30 minutos de intervalo. El objetivo de este análisis es utilizar una muestra donde los audios tengan la menor autocorrelación posible y, por lo tanto, no dependan los unos de los otros.

Para llevar a cabo esta prueba, se han utilizado los audios de la grabadora AM1 cogiendo 10 días de audios grabados en mayo, otra en julio, otra en septiembre y otra en mayo. Se realizó esta comparación temporal para determinar si en algún momento del año los datos eran más estacionarios que en otro.

De todos los audios escogidos, se crearon dos subconjuntos, uno de ellos con audios separados cada 10 minutos y otro con los mismos audios, pero solo con aquellos separados cada media hora. Lo primero fue obtener una serie temporal que contiene un valor de media por cada audio y representa todos los datos de cada subconjunto en un periodo de 10 días.

Una vez existía esta serie temporal, se calculó el contraste de Dickey-Fuller que indica si una serie temporal es estacionaria o no. Este contraste se aplicó para ambos subconjuntos recogidos en los cuatro meses elegidos. El resultado fue que en todos los casos se rechazaba la hipótesis nula y su *p-value* era inferior a 0.001. Esto indica que se rechaza la hipótesis nula y por tanto que todas las series son estacionarias.

Para poder observar qué series son más estacionarias se calculó el ACF (Anexo 1) y el PACF (Anexo 2) de cada una de ellas. Gracias a estas funciones se obtuvieron resultados más concretos.

Al observar los gráficos de ACF, se puede ver que, en el mes de mayo, la autocorrelación disminuye más drásticamente en los audios tomados cada media hora mientras que en los tomados cada 10 minutos la autocorrelación disminuye con mayor lentitud. Observando el intervalo de confianza, se puede identificar que las autocorrelaciones en los intervalos de 10 minutos son más significativas y, por tanto, en el conjunto tomado cada media hora se muestran más coeficientes dentro del intervalo de confianza.

En los gráficos tomados en julio y septiembre se presentan dos situaciones muy parecidas para ambos intervalos. Ambas muestras presentan series estacionarias y todas sus autocorrelaciones se encuentran dentro del intervalo de confianza.

En el caso de los gráficos que representan los datos de diciembre, ocurre como en el mes de mayo donde la serie temporal de las muestras tomadas cada media hora se presenta como más estacionaria y tiene más valores dentro del intervalo de confianza. Finalmente, a pesar de que ambas series temporales son estacionarias, se eligieron subconjuntos de audios separados cada media hora. Es por ello por lo que, para el resto del proyecto, los audios utilizados para calcular los índices y trabajar con ellos son obtenidos de un conjunto de datos de un minuto tomados con una separación de media hora entre ellos.

#### 4.2 Cálculo de índices acústicos

Teniendo el conjunto de datos definido, se han calculado los valores de los siete índices acústicos seleccionados (Tabla 1) para un conjunto de muestras aleatorias de cada grabadora.

Teniendo audios de cada una de las seis grabadoras divididos en 5 grupos según meses, se han cogido 400 audios de cada conjunto utilizando Bootstrap con reemplazamiento. De esta manera se ha obtenido un conjunto de 2000 audios por cada grabadora que forman una muestra aleatoria.

Estas muestras aleatorias se han utilizado para calcular el valor de los índices acústicos propuestos para todas las zonas (Tabla 4). Con estos valores obtenidos, podemos hacer una comparación sobre la diferencia entre índices en un mismo lugar y sobre la diferencia de un mismo índice calculado en lugares distintos.

### 4.3 Estudio espacial de los índices acústicos

Los índices nos ofrecen un resumen de propiedades matemáticas que de algún modo cuantifican los patrones biológicos o ambientales de una región o espacio.

Tiene interés por tanto realizar un estudio espacial sobre el comportamiento de cada uno de ellos en hábitats diferentes.

Para detectar si existen o no cambios significativos en los valores medios de cada índice en los diferentes hábitats se han creado modelos ANOVA. Este estudio permite contrastar la homogeneidad de diferentes poblaciones en cuanto al índice correspondiente (variable de estudio).

El estudio ANOVA requiere normalidad en la distribución de las poblaciones y sobre todo homocedasticidad, es decir que la variabilidad del índice de estudio no difiera mucho en los hábitats que se someten a comparación.

Existen sin embargo autores (Uriel, 1995) que señalan que aun no cumpliéndose esta condición el estadístico F no se vería seriamente afectado. Luego, se han reforzado los resultados con un contraste no paramétrico, que no requiere condiciones previas sobre la distribución, como la prueba de Mann-Whitney.

Para realizar estos modelos, se han juntado todos los datos de un mismo índice recogidos en los distintos ecosistemas y se ha incluido su hábitat como una variable factorizada. Teniendo esto, se ha usado el propio valor del índice como variable respuesta y el hábitat como variable factor. El resultado han sido 7 modelos (uno por cada índice) que indican la relación que tiene el hábitat con cada índice.

#### 4.3.1 Resultados ANOVA

El primero modelo calculado fue sobre el índice ADI y dio los siguientes resultados:

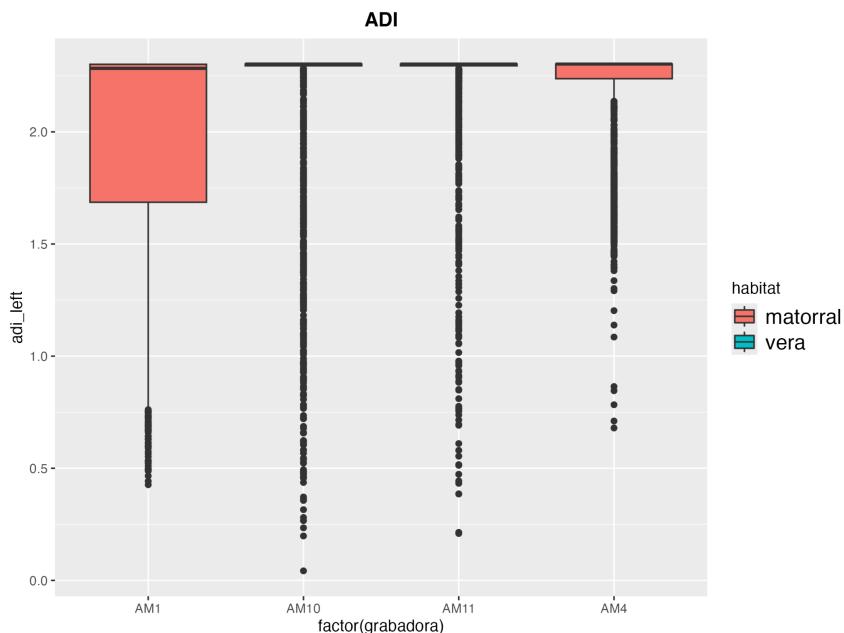
	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
ADI_global_df\$habitat	1	14.1	14.09	93.63	<2e-16	***
ADI_global_df\$habitat:factor(grabadora)	2	49.5	24.76	164.58	<2e-16	***
Residuals	6898	1037.9	0.15			
---						
Signif. codes:	0	***	0.001	**	0.01	‘.’ 0.05 ‘.’ 0.1 ‘ ’ 1

**Tabla 2:** Resultados del modelo ANOVA del índice ADI

Estos resultados indican varias características sobre la influencia del hábitat en este índice. El *F value* es la razón entre las variaciones entregrupos e intragrupo. En ese

caso, está indicando cuánto más grande es la variación entre los dos hábitats en comparación con la variación dentro de cada hábitat.

Por último, el  $Pr(>F)$  indica el p valor de F. En este caso el p-valor es más pequeño que el nivel de significación, por lo tanto, rechazamos la hipótesis nula indicando que hay una diferencia significativa entre los dos hábitats en términos de cómo afectan al valor del índice ADI. Por lo tanto, se puede decir que el entorno es un factor significativo en el cálculo del índice al nivel intra-grupo y al nivel entregrupo, ya que ambos p valores rechazan la hipótesis nula.



**Figura 2:** Resultados gráficos de modelo ANOVA sobre índice ADI

Gráficamente, podemos comprobar que los resultados del modelo ANOVA son correctos. En el caso matorral se ve más claramente como las grabadoras AM1 y AM4 tienen valores completamente distintos. Sin embargo, en el caso de las grabadoras de vera, sus resultados sí que son algo similares. Lo que se puede ver claramente es la diferencia entre las grabadoras de un hábitat y las del otro.

El segundo modelo calculado fue sobre el índice ACI y dio los siguientes resultados:

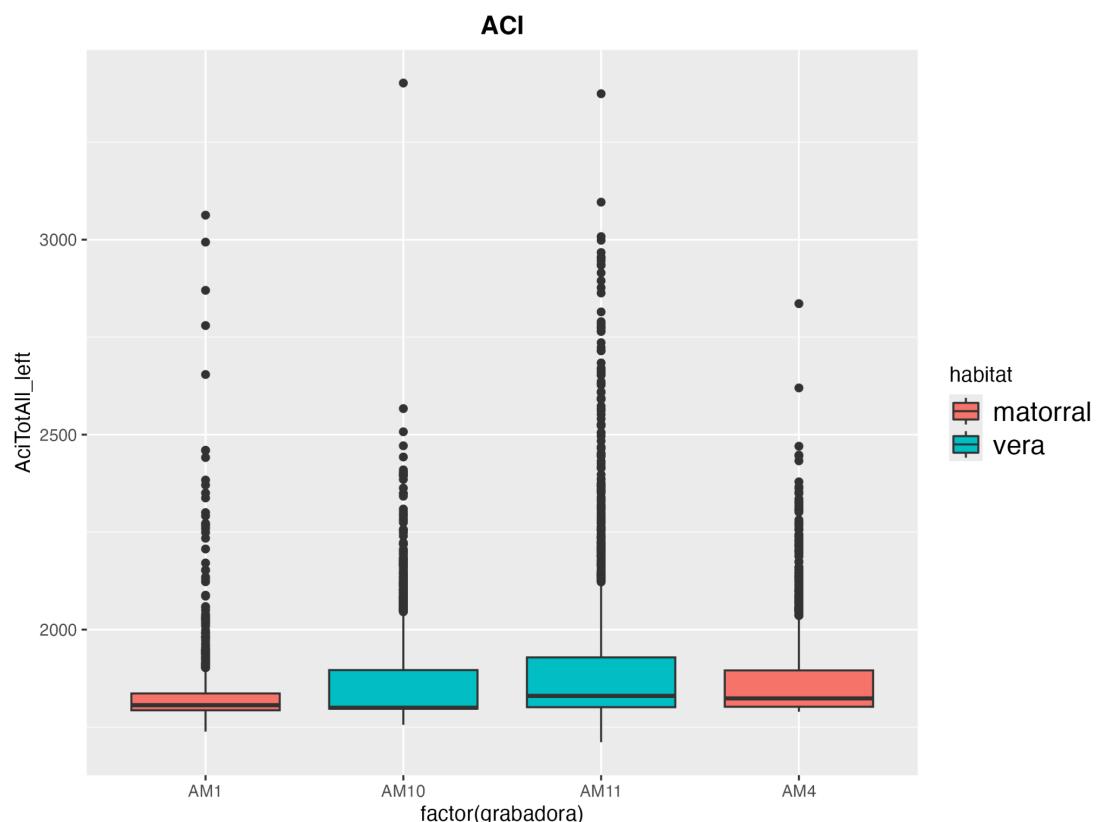
```

Df      Sum Sq Mean Sq F value Pr(>F)
ACI_global_df$habitat           1    2436897 2436897   128.9 <2e-16 *
ACI_global_df$habitat:factor(grabadora) 2    3158392 1579196    83.5 <2e-16 *
Residuals                      6877 130058777 18912
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

```

**Tabla 3:** Resultados del modelo ANOVA del índice ACI

Observando el *F value* y el *Pr(>F)*, podemos ver que se rechaza la hipótesis nula y que, por lo tanto, el factor hábitat es significativo en el cálculo del índice ACI. La hipótesis nula se rechaza de nuevo en el caso de las grabadoras intra-grupo y las entregrupo.



**Figura 3:** Resultados gráficos de modelo ANOVA sobre índice ACI

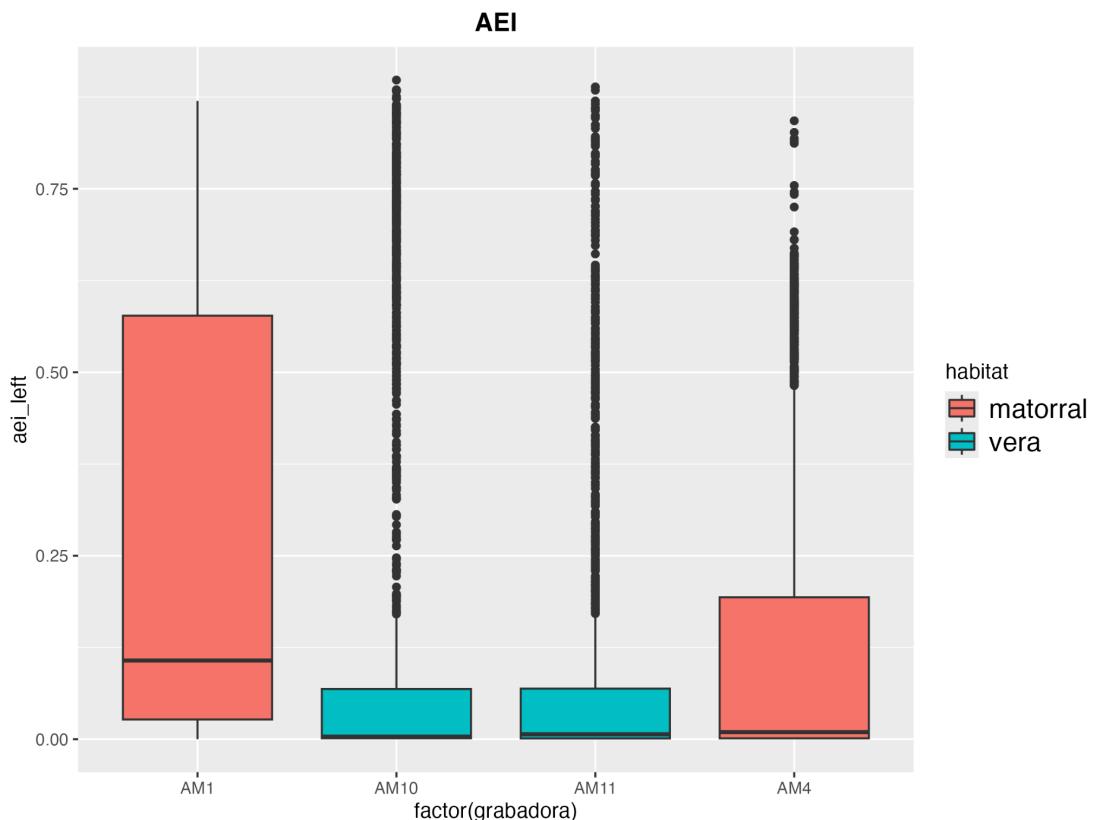
Sin embargo, en este caso el p valor no es tan pequeño como en el caso anterior, esto se puede ver reflejado en el gráfico ya que a pesar de ser diferentes, la diferencia entre los resultados de las 4 grabadoras no difiere de una forma tan drástica como en el índice anterior.

El tercer modelo calculado fue sobre el índice AEI y dio los siguientes resultados:

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
AEI_global_df\$habitat	1	12.3	12.269	199.1	<2e-16 ***
AEI_global_df\$habitat:factor(grabadora)	2	17.3	8.629	140.1	<2e-16 ***
Residuals	6898	425.0	0.062		
---					
Signif. codes:	0	***	0.001	**	0.01
	*	0.05	.	0.1	'
					1

**Tabla 4:** Resultados del modelo ANOVA del índice AEI

Al igual que en los dos casos anteriores, este modelo rechaza la hipótesis nula y por tanto indica que el factor hábitat es significativo a la hora de calcular el índice AEI. También se puede ver que el F value es más elevado todavía por lo que la variación entre hábitats es todavía mayor comparada con la variación dentro de cada hábitat.



**Figura 4:** Resultados gráficos de modelo ANOVA sobre índice AEI

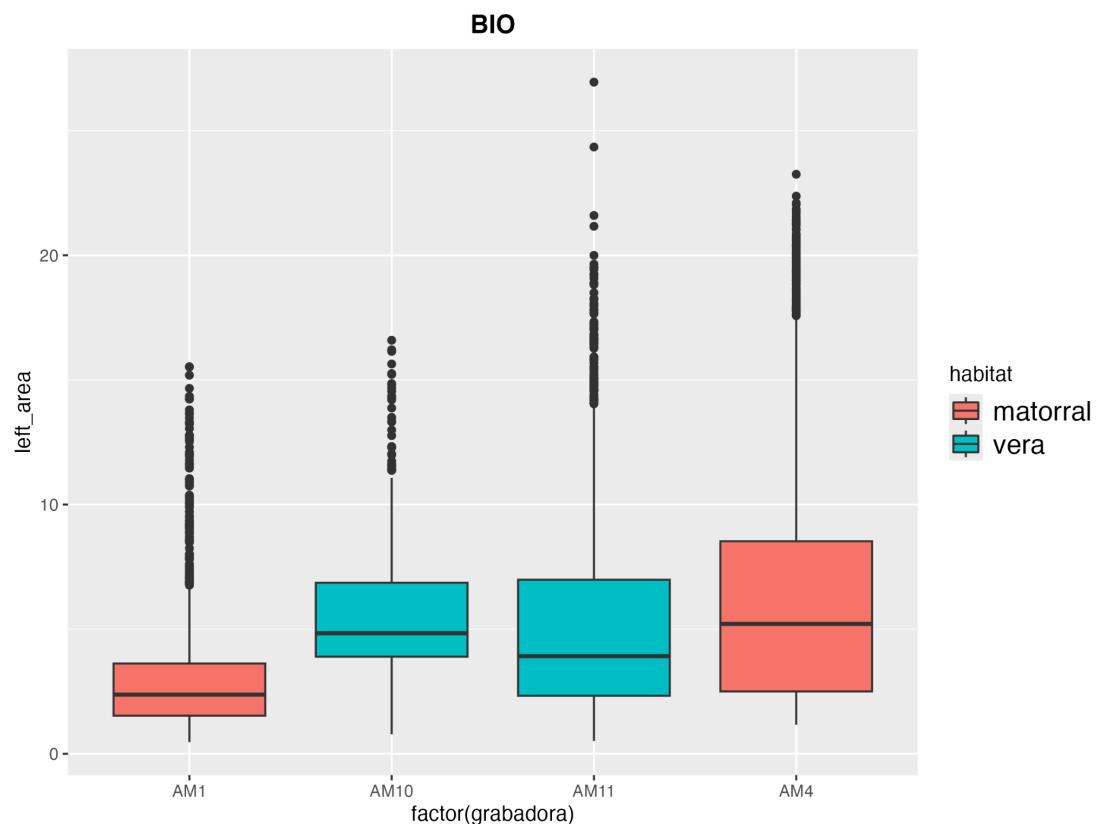
Gráficamente se puede comprobar los resultados de ANOVA, vemos que en el caso de las grabadoras de matorral son muy diferentes entre ellas y sobre todo muy diferentes comparadas con las de vera. Si que se puede ver que en el caso de las grabadoras AM10 y AM11, hay una similitud en sus resultados a nivel gráfico.

El cuarto modelo calculado fue sobre el índice BIO y dio los siguientes resultados:

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
BIO_global_df\$habitat	1	286	286	20.16	7.23e-06 **
BIO_global_df\$habitat:factor(grabadora)	2	10827	5414	382.25	< 2e-16 **
Residuals	6898	97693	14		
---					
Signif. codes:	0	***	0.001	**	0.01 *
					0.05 .
					0.1 ‘ ’ 1

**Tabla 5:** Resultados del modelo ANOVA del índice BIO

En este caso, según el valor de  $Pr(>F)$  también se rechaza la hipótesis nula y por tanto se determina que el hábitat es un factor significativo a la hora de calcular el índice BIO.



**Figura 5:** Resultados gráficos de modelo ANOVA sobre índice BIO

Sin embargo, observando la gráfica, se puede ver que la variación entre grupos no es mucho más grande que la variación intragrupos.

El quinto modelo calculado fue sobre el índice NDSI y dio los siguientes resultados:

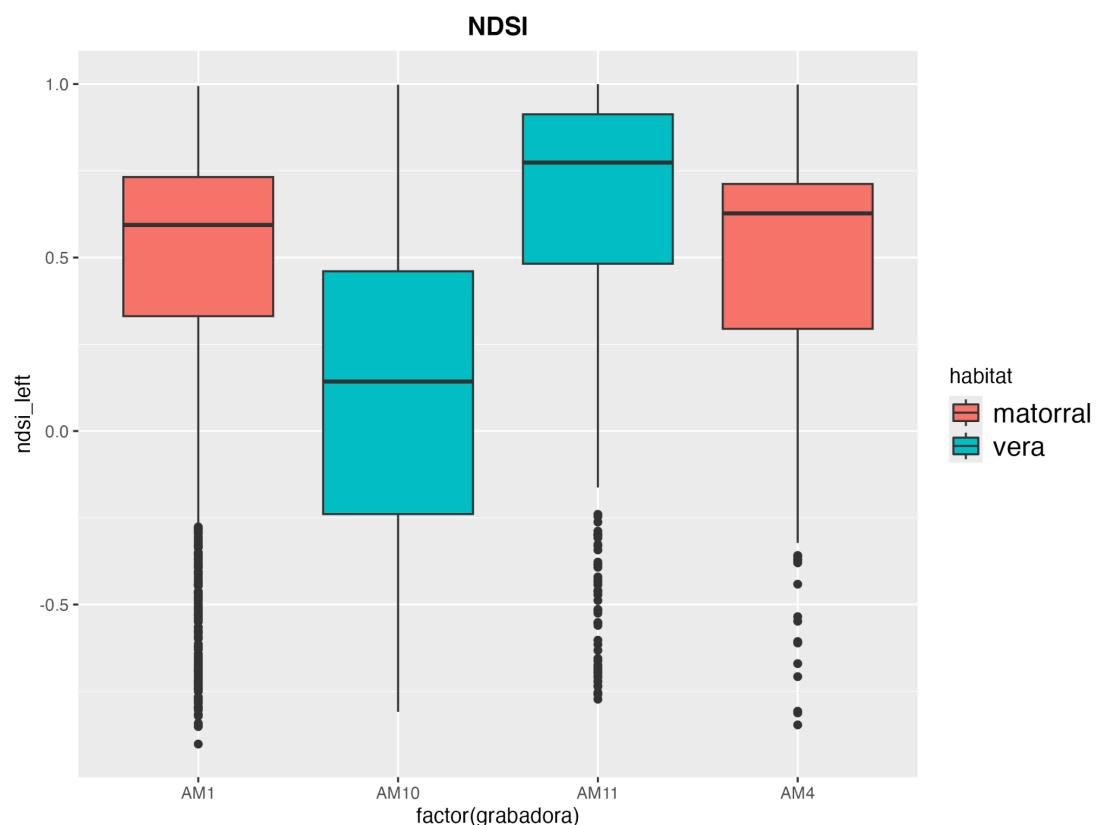
```

Df Sum Sq Mean Sq F value    Pr(>F)
NDSI_global_df$habitat           1    7.3   7.26   47.19 7.01e-12 *
NDSI_global_df$habitat:factor(grabadora) 2 242.9 121.45 789.62 < 2e-16 *
Residuals                      6877 1057.7   0.15
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

```

**Tabla 6:** Resultados del modelo ANOVA del índice NDSI

En este caso, una vez más se rechaza la hipótesis nula indicando que el hábitat es un factor significativo para obtener el índice NDSI.



**Figura 6:** Resultados gráficos de modelo ANOVA sobre índice NDSI

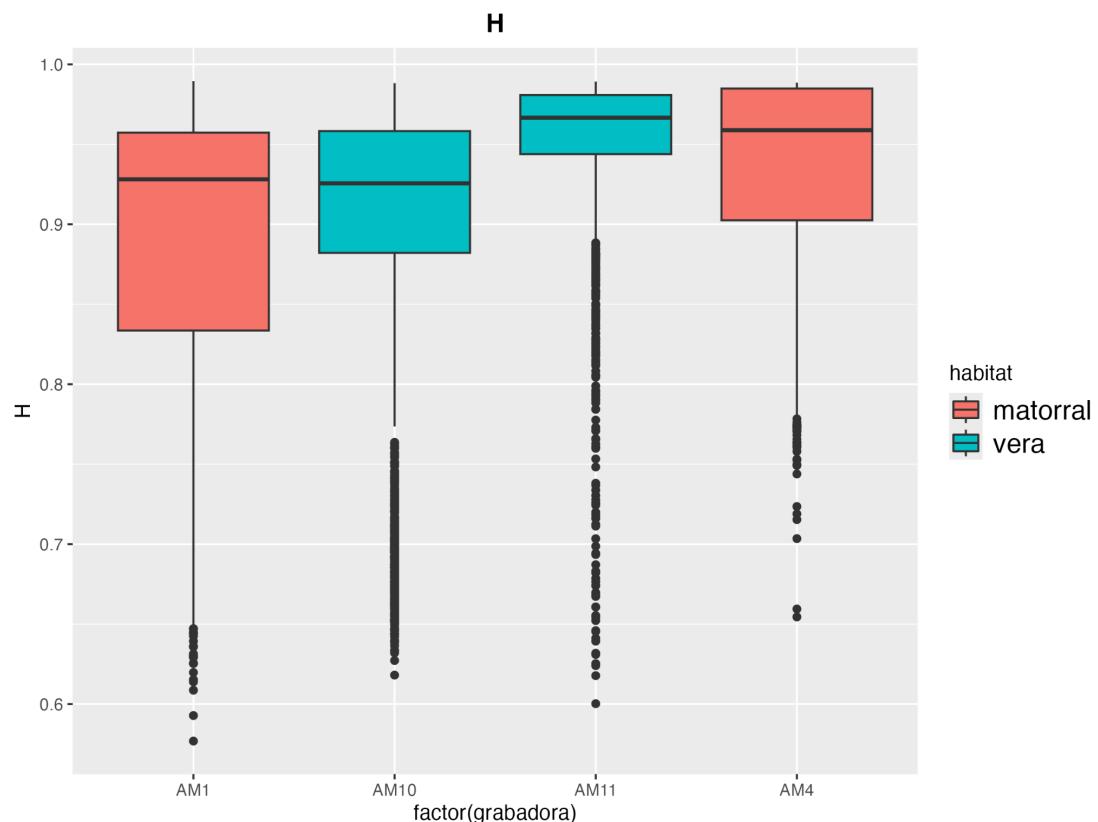
Una vez más, el p valor no es tan pequeño lo que nos indica que la diferencia intra-grupos y entregrupos no es tan grande. Gráficamente esto que respaldado ya que, a pesar de no ser resultados idénticos, las grabadoras no difieren tanto como en el caso de otros índices.

El sexto modelo calculado fue sobre el índice H y dio los siguientes resultados:

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
H_global_df\$habitat	1	0.12	0.1237	19.99	7.92e-06 ***
H_global_df\$habitat:factor(grabadora)	2	4.63	2.3156	374.27	< 2e-16 ***
Residuals	6898	42.68	0.0062		
---					
Signif. codes:	0	***	0.001	**	0.01 *
					0.05 .
					0.1 ‘ ’ 1

**Tabla 7: Resultados del modelo ANOVA del índice H**

En el caso del índice H, se rechaza la hipótesis nula indicando que el factor hábitat es significativo en el cálculo del índice H.



**Figura 7: Resultados gráficos de modelo ANOVA sobre índice H**

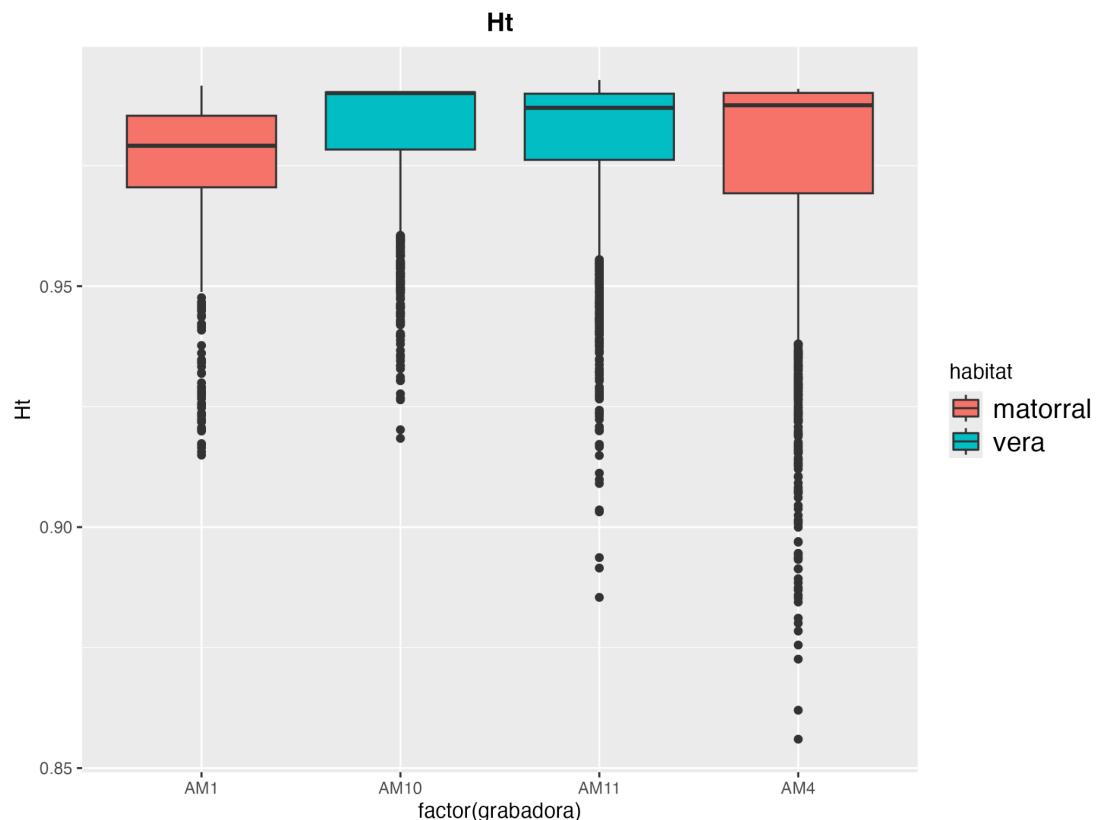
Gráficamente podemos ver una vez más la diferencia de los resultados de un mismo índice en lugares diferentes. Lo que demuestra de nuevo que el factor hábitat influye significativamente en el cálculo del índice H.

El séptimo modelo calculado fue sobre el índice Ht y dio los siguientes resultados:

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Ht_global_df\$habitat	1	0.0467	0.04669	169.55	< 2e-16 ***
Ht_global_df\$habitat:factor(grabadora)	2	0.0098	0.00490	17.78	1.98e-08 ***
Residuals	6898	1.8993	0.00028		
---					
Signif. codes:	0	***	0.001	**	0.01 *
					0.05 .
					0.1 ‘ ’
					1

**Tabla 8:** Resultados del modelo ANOVA del índice Ht

Una vez más, el  $Pr(>F)$  indica el rechazo de la hipótesis nula lo que demuestra que el factor hábitat es significativo para calcular el índice Ht. En este caso el *F value* del hábitat es mayor que el de grabadora, lo que indica que la variación entre grupos es mayor que la variación intra-grupos.



**Figura 8:** Resultados gráficos de modelo ANOVA sobre índice Ht

En el gráfico se puede ver cómo los resultados de las grabadoras contenidas en el mismo hábitat son algo similares, sobre todo en el caso del hábitat vera.

Después de haber realizado estos modelos, se puede concluir que en el caso de los 7 índices el factor hábitat es muy significativo a la hora de calcularlos. Al ser modelos con muchos datos, se aplicó la corrección de Benjamini-Hochberg para controlar el

descubrimiento falso y en todos los casos el *p-value* obtenido era igual al del modelo, lo que ha confirmado que los modelos ANOVA estaban correctos.

Tras realizar modelos ANOVA, se aplicó el contraste de Levène que mide la homocedasticidad de los datos. En todos los casos, el p valor de este contraste da un valor mucho menor al nivel de significancia (0,005) por lo que se rechaza la hipótesis nula indicando que hay heterocedasticidad en los datos utilizados. A pesar de que esto hace que los datos no cumplan con todas las características necesarias para aplicar ANOVA, hay muchos autores que defienden que el estadístico F no se ve altamente afectado por la heterocedasticidad.

Al haber aplicado ANOVA sin cumplir todas las características, a continuación, se ha realizado un contraste de Mann-Whitney para profundizar en la relación intragrupo de cada índice.

#### 4.3.2 Contraste de Mann-Whitney

Teniendo 2000 valores de índices acústicos por cada una de las grabadoras. Se ha aplicado un primer contraste de Mann-Whitney sobre cada pareja de grabadoras que pertenece a un mismo hábitat para cada uno de los 7 índices. Esta prueba permite identificar si dos grupos no paramétricos pertenecen a una misma población.

### Contraste de Mann-Whitney

Combinación	W	P-Valor	Habitat
ADI (AM1 y AM4)	802502	< 2,2e - 16	Matorral
ADI (AM10 y AM11)	1584000	0,5089	Vera
ACI (AM1 y AM4)	928665	< 2,2e - 16	Matorral
ACI (AM10 y AM11)	1166871	< 2,2e - 16	Vera
AEI (AM1 y AM4)	2022270	< 2,2e - 16	Matorral
AEI (AM10 y AM11)	1553334	0,7265	Vera
BIO (AM1 y AM4)	690533	< 2,2e - 16	Matorral
BIO (AM10 y AM11)	1868801	< 2,2e - 16	Vera
NDSI (AM1 y AM4)	1359509	0,05823	Matorral
NDSI (AM10 y AM11)	607319	< 2,2e - 16	Vera
H (AM1 y AM4)	903929	< 2,2e - 16	Matorral
H (AM10 y AM11)	782459	< 2,2e - 16	Vera
Ht (AM1 y AM4)	1019250	< 2,2e - 16	Matorral
Ht (AM10 y AM11)	1923231	< 2,2e - 16	Vera

**Tabla 9:** Resultados de prueba de Mann-Whitney

Observando los resultados, se puede ver que en todos los casos a excepción de dos el *p-valor* es inferior al nivel de significación. Esto indica que en esos casos se rechaza la hipótesis nula y por ello, se concluye que las dos grabadoras no pertenecen a la misma población.

Para corroborar los resultados de la prueba, se puede observar que gráficamente los dos únicos casos en los que los boxplot de las dos grabadoras son prácticamente iguales son los de los índices ADI y AEI aplicados en las grabadoras AM10 y AM11. Esta interpretación gráfica coincide con las conclusiones obtenidas del contraste de Mann-Whitney.

Gracias a este contraste, se ha podido verificar lo indicado por ANOVA. Aplicando el contraste de Mann-Whitney, se confirma que hay diferencias significativas entre los

valores del índice hallados en zonas diferentes de un mismo hábitat a excepción de los dos casos indicados donde se puede confirmar gráficamente que los valores de los índices ADI y AEI en el hábitat vera no varían prácticamente entre la grabadora AM10 y AM11.

#### **4.4 Estudio temporal de los índices acústicos**

Tras haber realizado un estudio espacial de los valores de los índices, se pasó al estudio temporal de los mismos. Los datos sobre los que se han calculado los valores fueron recogidos entre mayo y diciembre de 2023. Esto permite hacer un estudio temporal de las estaciones de primavera, verano y otoño para determinar el comportamiento de cada índice durante ese tiempo.

En primer lugar, se obtuvieron series temporales que representarán los valores de los índices. Para crear estas series temporales, se juntaron todos los valores del mismo índice calculados en todas las zonas y se tomó aleatoriamente un dato por día. De manera que el resultado fueron 7 series temporales desde mayo hasta octubre compuestas por valores tomados de todas las grabadoras (Anexo 3). Observando las gráficas de estas series temporales, se puede ver que tienen comportamientos variados. En el caso de ADI se puede ver que durante los meses de agosto y septiembre su valor disminuye y a partir de octubre vuelve a aumentar. Lo mismo ocurre, pero con una curva más suave para los índices BIO y H. Sin embargo, en el caso de ACI y AEI, se observa que, tras la bajada de los meses de verano, su valor sigue disminuyendo durante el otoño en vez de volver a subir como en los índices anteriores.

En el caso del índice NDSI, observamos que su valor disminuye desde el principio y en el otoño tiene una baja muy drástica. Por último, el índice Ht mantiene una subida ligera hasta septiembre cuando empieza a aumentar su valor de manera mucho más rápida.

Al haber concluido que el valor de los índices se ve afectado por el hábitat en el que han sido calculados, se han realizado los mismos gráficos a partir de series temporales con valores únicamente de un mismo hábitat.

En el caso de las series temporales sobre matorral (Anexo 4), se puede observar que los índices ADI y ACI tienen un comportamiento bastante diferente al de la serie

temporal global de su mismo índice. Mientras que, en el caso del resto de los índices, sus trayectorias difieren ligeramente de la trayectoria global.

Observando las gráficas de las series temporales de los índices tomados en el hábitat vera (Anexo 4), podemos ver que sus trayectorias son muy parecidas a las de los gráficos globales en general.

#### 4.4.1 Estudio de factores con modelos mixtos

Después de analizar los gráficos de las series temporales. Se han explorado modelos mixtos con distintos factores para entender cuál funciona mejor.

Para cada índice, se han desarrollado tres modelos, un primero modelo lineal que intenta predecir el índice usando el hábitat como variable predictora de la siguiente manera: `modelo1 <- lm(valor_indice ~ habitat, data = data)`.

Luego se ha calculado un segundo modelo lineal mixto incluyendo la grabadora como efecto aleatorio la grabadora a la que pertenece cada valor:

`modelo2 <- lmer(valor_indice ~ habitat + (1 | grabadora), data = data)`.

Por último, se ha calculado un tercer modelo mixto añadiendo como segundo efecto aleatorio la fecha de cada valor:

`modelo3 <- lmer(valor_indice ~ habitat + (1 | grabadora) + (1 | fecha), data = data)`.

#### Evaluación de los modelos temporales de cada índice

Índice	AIC modelo1	AIC modelo2	AIC modelo3
ADI	<b>187,8818</b>	195,2461	196,653
ACI	2672,359	2660,515	<b>2614,242</b>
AEI	<b>59,16168</b>	64,17327	67,92259
BIO	1189,299	1187,068	<b>1178,583</b>
NDSI	228,6268	200,8995	<b>199,5676</b>
H	-436,0515	-426,5656	<b>-413,5002</b>
Ht	-1101,994	-1078,596	<b>-1041,884</b>

**Tabla 10:** AIC de los tres modelos realizados sobre cada índice

Obteniendo los resultados de estos tres modelos, se han comparado sus AIC para elegir cuál funciona mejor en cada caso.

En el caso de los índices ADI y AEI, el modelo con el AIC más bajo es el primero, esto nos indica que, para estos dos índices, el modelo lineal que predice el valor del índice utilizando el factor hábitat como predictor, es el que da un resultado más significativo.

```

Call:
lm(formula = adi_left ~ habitat, data = ADI)

Residuals:
    Min      1Q  Median      3Q     Max 
-1.81738  0.09777  0.11322  0.22220  0.22349 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 2.07909   0.03576  58.139 <2e-16 ***
habitat1    0.11027   0.05130   2.149   0.0328 *  
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.3734 on 210 degrees of freedom
Multiple R-squared:  0.02152, Adjusted R-squared:  0.01686 
F-statistic:  4.62 on 1 and 210 DF,  p-value: 0.03275

```

**Tabla 11:** Modelo más significativo para el índice ADI

En el caso del modelo del índice ADI, se puede observar que su *p*-valor es inferior al nivel de significancia (0.005) por lo que podemos decir que el hábitat es estadísticamente significativo a la hora de calcular la variable respuesta (ADI).

```

Call:
lm(formula = aei_left ~ habitat, data = AEI)

Residuals:
    Min      1Q  Median      3Q     Max 
-0.2469 -0.1707 -0.1436  0.1966  0.6746 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 0.24701   0.02770  8.918 2.35e-16 ***
habitat1   -0.09994   0.03794 -2.634  0.00906 ** 
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.2756 on 210 degrees of freedom
Multiple R-squared:  0.03198, Adjusted R-squared:  0.02737 
F-statistic: 6.939 on 1 and 210 DF,  p-value: 0.009064

```

**Tabla 12:** Modelos más significativo para el índice AEI

En el caso del índice AEI podemos llegar a la misma conclusión que en el índice anterior. Que el primer modelo haya sido el más significativo de estos casos, indica que, según la complejidad de los datos, el modelo sin factores aleatorios se ajusta mejor a ellos.

En el caso de los índices ACI, BIO, NDSI, H y Ht ocurre lo contrario, ya que el modelo con el AIC más bajo es el tercero. Esto quiere decir que el modelo mixto que tiene como variable fija el hábitat y como variables predictoras la grabadora y la fecha hace un mejor trabajo en ajustarse a los datos según su complejidad.

```

REML criterion at convergence: 1168.6

Scaled residuals:
    Min      1Q   Median      3Q     Max
-0.8178 -0.4425 -0.1650  0.2502  2.2882

Random effects:
 Groups   Name        Variance Std.Dev.
 datetime (Intercept) 8.655    2.942
 grabadora (Intercept) 1.135    1.065
 Residual             6.529    2.555
Number of obs: 210, groups: datetime, 210; grabadora, 4

Fixed effects:
            Estimate Std. Error t value
(Intercept)  4.9695    0.8451  5.881
habitat1     0.3159    1.1938  0.265

Correlation of Fixed Effects:
              (Intr)
habitat1 -0.708

```

**Tabla 13:** Modelo con mejor resultado para el índice BIO

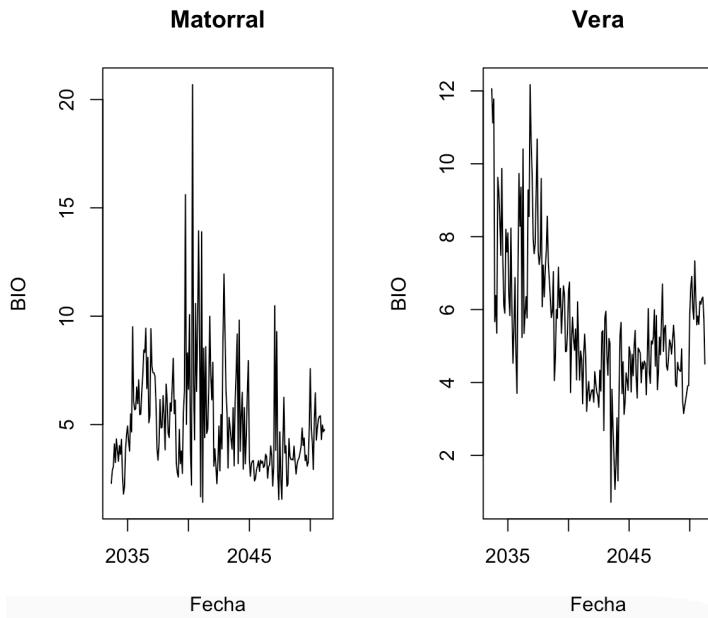
En los modelos mixtos, podemos ver el valor del *Criterio de máxima verosimilitud restringida (REML)* que indica cómo de bien se ha ajustado el modelo a los datos. En el caso de todos los índices cuyo mejor modelo es el tercero, su valor de *REML* también es el menor de los tres calculados.

En ninguno de los casos el mejor modelo ha sido el segundo, esto quiere decir que los modelos se estos índices se adaptan mejor a los datos cuando se considera como variable aleatoria el tiempo y la grabadora más que cuando se considera únicamente la grabadora.

#### 4.4.2 Modelización ARIMA

Para profundizar en el estudio temporal, se ha realizado una modelización ARIMA sobre el índice BIO ya que es uno de los más populares en el campo de la ecoacústica y parece dar buenos resultados en este proyecto. Primero se han generado dos series temporales, una de ellas contiene un valor medio de este índice por día tomado de las grabadoras situadas en matorral y otra tiene la misma estructura pero con datos del índice obtenidos de las grabadoras situadas en vera.

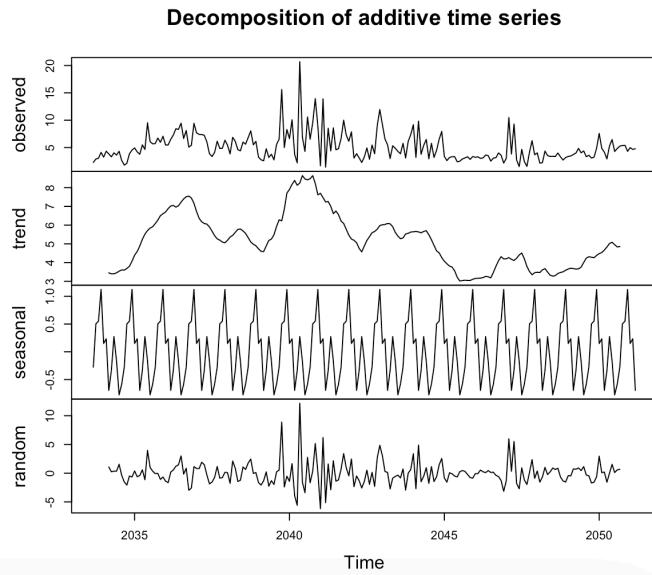
Teniendo estas dos series temporales, primero se ha realizado una representación gráfica de ellas:



**Figura 9:** Gráficos de las series temporales del índice BIO en vera y en matorral

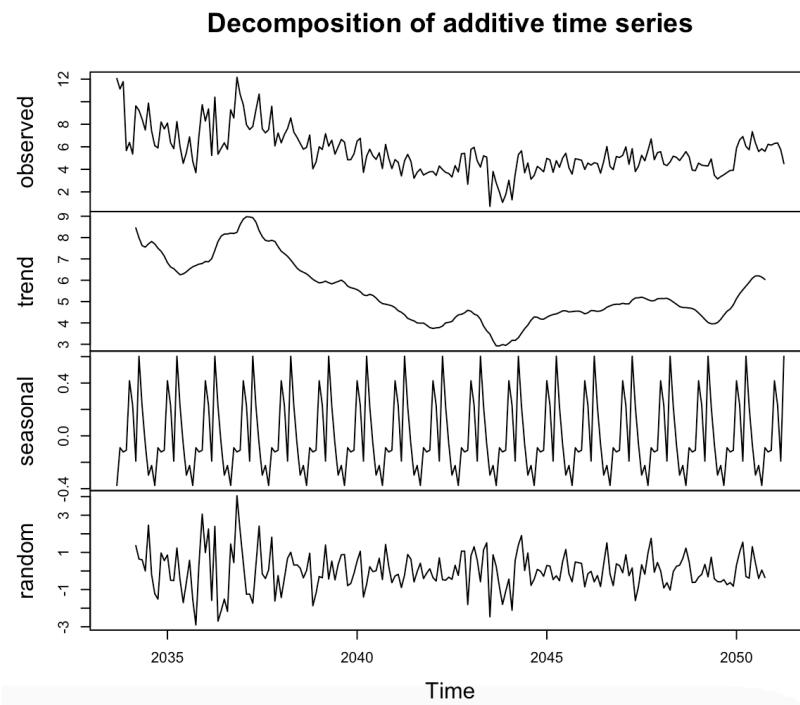
Observando solamente estas dos gráficas, podemos ver que en cada hábitat presenta una evolución diferente como se ha podido comprobar en el estudio temporal realizado anteriormente. Por ello, se procedió a estudiar cada serie temporal por separado.

Primero se aplicó la función *decompose()* de R que muestra los componentes básicos de una serie temporal:



**Figura 10:** Descomposición de la serie temporal del índice BIO en matorral

En esta figura del índice BIO en matorral, podemos ver en la fila superior una representación secuencial de la serie temporal. En la segunda fila muestra la tendencia subyacente de la serie, esta gráfica es el resultado de minimizar los datos para eliminar ruido. En ella podemos identificar una clara subida de los valores del índice en semanas de primavera seguida por una baja en las semanas de verano que se va recuperando a medida que entra el otoño. La tercera columna muestra la estacionalidad de la serie según la frecuencia establecida que en este caso es semanal. En este caso podemos identificar patrones repetitivos a lo largo del ciclo establecido. La cuarta fila muestra la variabilidad aleatoria, lo que indica que donde se encuentran los puntos elevados, hay valores que no son explicados por la tendencia marcada y por lo tanto indican eventos inusuales. En este caso, vemos que claramente hay eventos inusuales en esas semanas de primavera donde aumenta mucho el valor de BIO.



**Figura 11:** Descomposición de la serie temporal del índice BIO en vera

En el caso de la serie temporal de vera, podemos identificar una tendencia diferente, donde el pico de mayor valor ocurre más al principio de la primavera seguido de una bajada más uniforme de los valores del índice que se va recuperando en el otoño. Con respecto a la estacionalidad los resultados son también diferentes con respecto al gráfico anterior mostrando dos picos muy claros por semana. La tercera fila, muestra

un gráfico de los valores aleatorios con más eventos inusuales que en el otro hábitat. En este caso vemos sobre todo valores inusuales al principio de la primavera y en el punto del verano donde los valores son más bajos.

#### 4.4.2.1 Análisis de estacionariedad

Para estudiar la estacionariedad más a fondo, se ha aplicado el Dickey-Fuller test en ambas series temporales:

```
Augmented Dickey-Fuller Test

data: ts_BIO_matorral
Dickey-Fuller = -3.9545, Lag order = 5, p-value = 0.01242
alternative hypothesis: stationary
```

**Tabla 14:** Resultado del test de Dickey-Fuller de la serie temporal del índice BIO en matorral

Observando el resultado de este test para la serie temporal del índice BIO en el hábitat matorral, podemos concluir que la serie es estacionaria ya que su  $p$  valor es menor que el nivel de significancia (0.05) y por lo tanto se rechaza la hipótesis nula aceptando la alternativa. Esta hipótesis alternativa indica que la serie temporal es estacionaria.

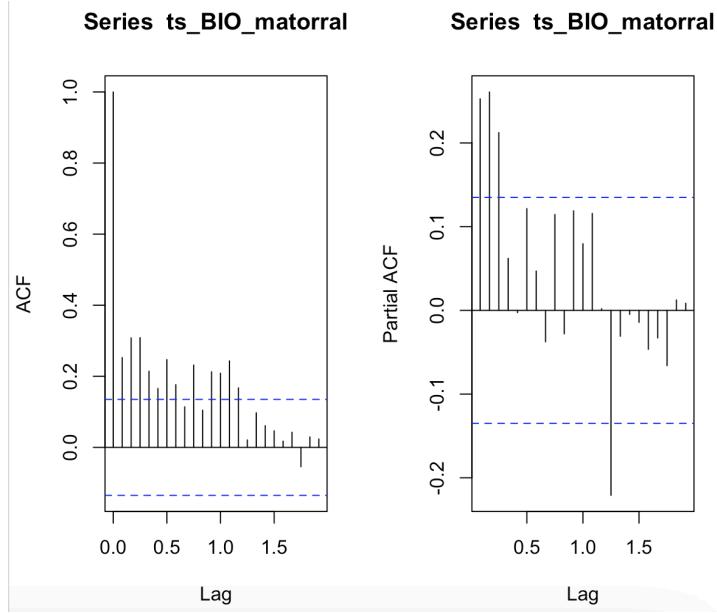
```
Augmented Dickey-Fuller Test

data: ts_BIO_vera
Dickey-Fuller = -2.8069, Lag order = 5, p-value = 0.2377
alternative hypothesis: stationary
```

**Tabla 15:** Resultado del test de Dickey-Fuller de la serie temporal del índice BIO en vera

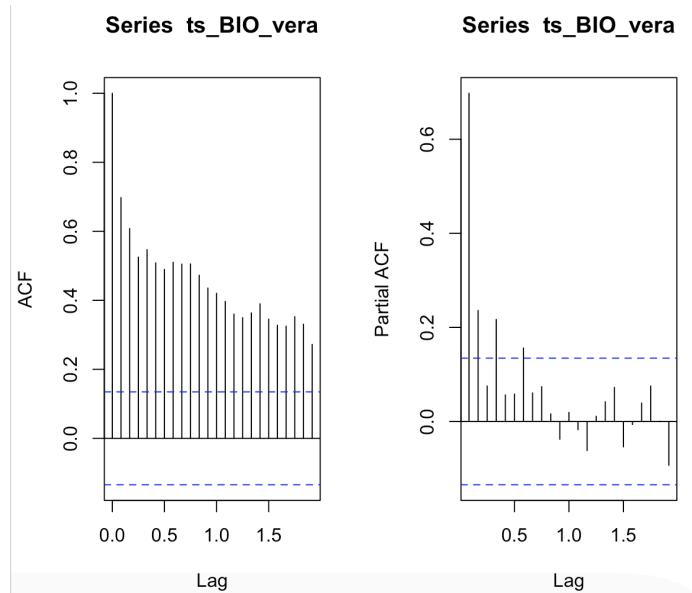
El test realizado sobre la serie temporal recogida de los datos de vera muestra un  $p$  valor mayor que el nivel de significancia, por lo que no se puede rechazar la hipótesis nula indicando que esta serie temporal no es estacionaria.

Para analizar la serie temporal más profundamente, se calcularon los gráficos de ACF y PACF.



**Figura 12:** Gráficos de ACF y PACF de la serie temporal del índice BIO en matorral

Según el gráfico ACF de la serie en matorral, podemos ver que es estacionaria ya que sus valores disminuyen rápidamente. Esto también nos indica que cuanto más separados en el tiempo se encuentran dos valores, menos correlacionados están. Observando el PACF, podemos sacar las órdenes de  $p$  y  $q$  para el modelo ARIMA. En este caso, al ser el tercer valor del PACF el que entra en el rango de normalidad, vamos a probar con valores de 1 2 y 3 para  $p$  y valores de 1 2 y 3 para  $q$ .



**Figura 13:** Gráficos de ACF y PACF de la serie temporal del índice BIO en vera

En el gráfico ACF de esta serie temporal, podemos ver que los valores no disminuyen drásticamente, lo que indica que esta serie no es estacionaria y que sus valores están altamente correlacionados. Según el PACF, se puede decir que los valores de  $p$  y  $q$  que se van a usar para el modelo ARIMA serían las mismas posibilidades que en la serie anterior pero en este caso, al ser una serie no estacionaria, el valor de  $d$  será siempre mayor que cero; probaremos con  $d=1$ .

#### 4.4.2.2 Obtención de modelos ARIMA

Habiendo elegido los valores para crear los modelos, se han creado 8 modelos ARIMA para cada serie temporal probando con las distintas combinaciones de  $p$  y  $q$  y se ha mirado el valor de su AIC para elegir el mejor.

```
Call:
arima(x = ts_BIO_matorral, order = c(1, 0, 1))

Coefficients:
          ar1      ma1  intercept
          0.9398 -0.7848    5.0010
  s.e.  0.0376  0.0673   0.5575

sigma^2 estimated as 5.62:  log likelihood = -481.73,  aic = 971.47

Training set error measures:
        ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.04103223 2.370595 1.555422 -18.08473 36.14897 0.7955944 -0.05419553
```

**Tabla 16:** Resultados del mejor modelo de ARIMA para matorral

Estos han sido los resultados del mejor modelo dentro de los 8 que se han probado. En este caso, los coeficientes de  $p$  y  $q$  han sido 1. Además de buscar el modelo manualmente, se aplicó auto ARIMA a la serie temporal para comprobar si se obtenía un modelo mejor:

```
Series: ts_BIO_matorral
ARIMA(0,1,1)

Coefficients:
      ma1
      -0.8380
  s.e.  0.0423

sigma^2 = 5.788:  log likelihood = -482.43
AIC=968.86  AICc=968.92  BIC=975.56
```

**Tabla 17:** Resultado de aplicar auto arima a la serie temporal del índice BIO en matorral

Se puede ver que en el modelo encontrado por auto ARIMA, la AIC es ligeramente mejor que en el anterior sin embargo, este modelo tiene como valor de  $d$  un 1 pero

nuestra serie es estacionaria, por lo que el valor de  $d$  debe ser 0. Por ello, se va a utilizar el modelo ARIMA(1,0,1).

```

Call:
arima(x = ts_BIO_vera, order = c(1, 1, 1))

Coefficients:
        ar1      ma1
    0.2831 -0.8260
  s.e.  0.1001  0.0642

sigma^2 estimated as 1.617:  log likelihood = -350.44,  aic = 706.87

Training set error measures:
          ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.102863 1.268555 0.92243 -8.325368 20.74241 0.8866858 -0.008910935

```

**Tabla 18:** Resultados del mejor modelo de ARIMA para vera

Este es el resultado del mejor modelo obtenido para la serie temporal de vera. En este caso, como la serie no es estacionaria, el valor de  $d$  sí que debe ser 1. Para comparar, se ha calculado el mejor modelo obtenido por auto arima.

```

Series: ts_BIO_vera
ARIMA(2,1,2)(2,0,2)[12] with drift

Coefficients:
        ar1      ar2      ma1      ma2      sar1      sar2      sma1      sma2      drift
    -0.2942  0.2174 -0.2837 -0.4574  0.6299 -0.7813 -0.6198  0.6471 -0.0188
  s.e.  0.4054  0.1207  0.4029  0.3135  0.2537  0.2364  0.2979  0.2978  0.0190

sigma^2 = 1.606:  log likelihood = -346.15
AIC=712.3  AICc=713.4  BIC=745.81

```

**Tabla 19:** Resultado de aplicar auto arima a la serie temporal del índice BIO en matorral

En este caso, el modelo que propone auto arima tiene un AIC mayor al modelo obtenido manualmente. Es por ello que se va a utilizar el modelo ARIMA(1,1,1) para la serie temporal del índice BIO en vera.

#### 4.4.2.3 Validación de modelos ARIMA

Habiendo obtenido un modelo definitivo para cada serie temporal, el último paso ha sido validar ambos modelos.

Primero se ha validado el modelo ARIMA(1,0,1) obtenido para la serie temporal de matorral.

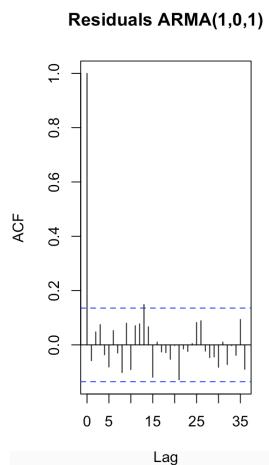
El primer paso de la validación, es comprobar que los coeficientes estimados sean significativos. Para ello, se ha aplicado el contraste de significación de coeficientes sobre el modelo.

ar1	ma1	intercept
3.944284e-138	1.874116e-31	2.965075e-19

**Tabla 20:** Resultado del contraste de significación de coeficientes en matorral

El resultado de este contraste devuelve p valores inferiores al nivel de significación (0,01) lo que lleva a rechazar la hipótesis nula y declarar que los coeficientes estimados por este modelo son significativos.

La segunda comprobación que se debe hacer es asegurarse de que los residuos del modelo se comportan como ruido blanco. Esto quiere decir que deben tener una media de 0, una varianza constante y una autocorrelación nula.



**Figura 14:** Resultado de ACF de los residuos del modelo ARIMA en matorral

Observando el ACF de los residuos, se puede comprobar que los valores están dentro de las bandas lo que indica que los valores no tienen correlación. Para comprobar esta correlación usando un contraste, se ha aplicado el test Ljung-Box sobre los residuos para estudiar su autocorrelación.

Box-Ljung test

```
data: resid1
X-squared = 58.524, df = 40, p-value = 0.02943
```

**Tabla 21:** Resultado del contraste Ljung-Box en los residuos del modelo en matorral

Con un nivel de significación de 0.01, no rechazamos la hipótesis nula y por lo tanto, podemos decir que los residuos de este modelo no tienen autocorrelaciones significativas.

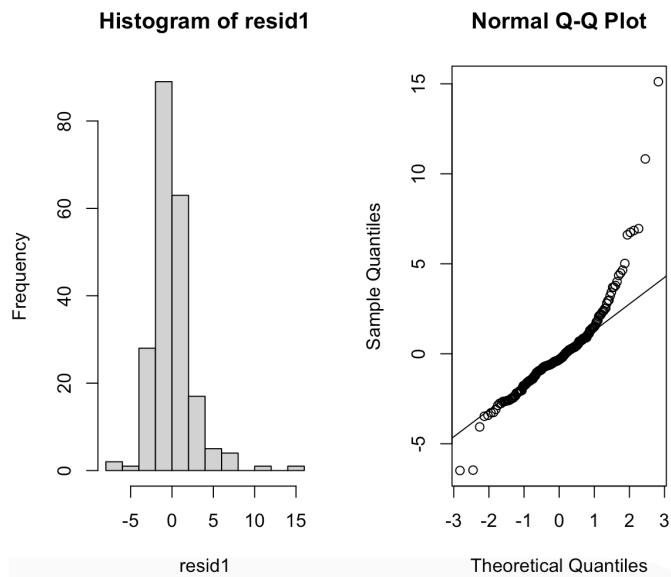
Para comprobar si estos residuos siguen una distribución normal o no, se ha aplicado el test de Shapiro-Wilk.

#### Shapiro-Wilk normality test

```
data: resid1
W = 0.85568, p-value = 3.258e-13
```

**Tabla 22:** Resultados del test de Shapiro-Wilk en el modelo ARIMA de matorral

El  $p$  valor de este test es menor que el nivel de significación y por tanto rechaza la hipótesis nula, lo que indica que la distribución que presentan los residuos no es normal.



**Figura 15:** Distribución de los residuales del modelo ARIMA en matorral

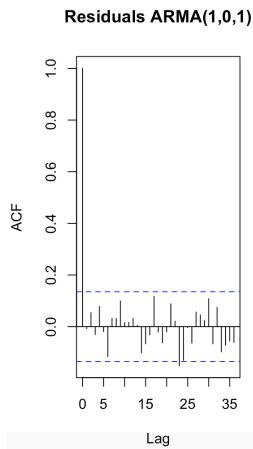
En la representación gráfica de los residuos, se puede comprobar que efectivamente, su distribución no es normal.

A continuación, se aplicaron estos mismo pasos de validación en el modelo ARIMA(1,1,1) obtenido para la serie temporal del índice BIO en vera. El primer paso es estudiar la significación de los coeficientes.

ar1	ma1
4.670373e-03	7.454905e-38

**Tabla 23:** Resultado del contraste de significación de coeficientes en vera

Este contraste devuelve unos  $p$  valores menores que el nivel de significación y por lo tanto se rechaza la hipótesis nula. Esto indica que en este modelo, todos los coeficientes son significativos.



**Figura 16:** Resultado de ACF de los residuos del modelo ARIMA en vera

A continuación, se estudian los residuos del modelo. Gráficamente podemos ver que todos los valores del ACF de los residuos se encuentran dentro de la franja de normalidad, por lo que se puede decir que los residuos no tienen autocorrelación.

```
Box-Ljung test
data: resid1
X-squared = 45.345, df = 40, p-value = 0.2589
```

**Tabla 24:** Resultado del contraste Ljung-Box en los residuos del modelo en vera

Aplicando el contraste Ljung-Box, se obtiene un  $p$  valor mayor que el nivel de significación por lo que no se rechaza la hipótesis nula y se puede decir que los residuos no tienen autocorrelaciones significativas entre ellos.

```

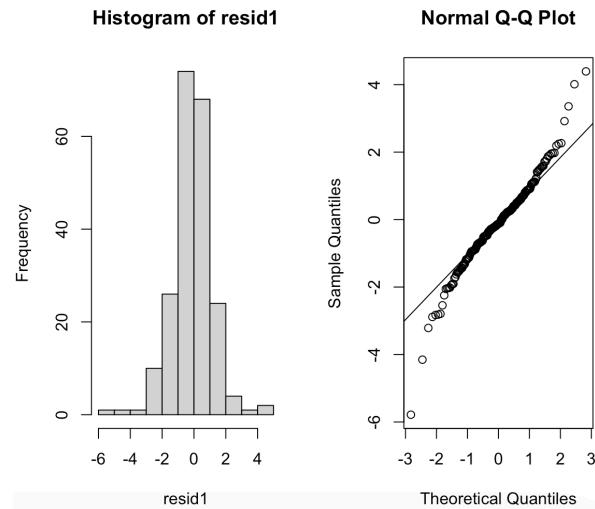
Shapiro-Wilk normality test

data: resid1
W = 0.96671, p-value = 6.795e-05

```

**Tabla 25:** Resultados del test de Shapiro-Wilk en el modelo ARIMA de vera

El test de Shapiro-Wilk, da un  $p$  valor menor que el nivel de significación por lo que se rechaza la hipótesis nula y confirma que los residuos del modelo no siguen una distribución normal.



**Figura 17:** Distribución de los residuales del modelo ARIMA en vera

Observando las gráficas de los residuos, se puede comprobar que efectivamente la distribución que siguen no es normal.

## 5. DISCUSIONES

Este trabajo ha presentado un estudio estadístico del funcionamiento de los índices acústicos como indicadores de diversidad de las especies de aves situadas en el Parque Nacional de Doñana. Para este análisis, se ha mantenido el enfoque en dos grabadoras situadas en el ecosistema matorral y otras dos situadas en el ecosistema de vera. Dicho análisis ha tenido tres partes principales.

Primero se analizó qué frecuencia de muestreo era la más apropiada para calcular los índices. Se estudió qué intervalo de tiempo entre cada audio daba un conjunto lo más estacionario posible y que por tanto tuviese la menor autocorrelación. El objetivo de este punto era que las grabaciones seguidas fueran lo menos dependientes las unas de las otras como fuera posible. La conclusión fue utilizar grabaciones de un minuto tomadas cada media hora. Aplicando bootstrapping o técnicas iterativas de remuestreo tratamos de evitar al máximo las autocorrelaciones o dependencias que pueden existir en datos tomados en el mismo período y el mismo lugar.

Una vez se calcularon los índices acústicos en cada una de las grabadoras utilizando una muestra aleatoria, se procedió a su análisis espacial y temporal.

El análisis espacial concluyó que los índices acústicos varían en función del hábitat del que proceden las grabaciones. Esta información concuerda con otros estudios realizados con índices acústicos en otros lugares del mundo que mostraban diferencias de sus valores según el hábitat (Bradfer-Lawrence et al., 2023). Gracias a los modelos ANOVA y el contraste Mann-Whitney se ha podido demostrar que esta distinción se cumple también en los ecosistemas contenidos en Doñana. Se ha determinado que el nivel de sensibilidad de los índices con respecto a su hábitat afecta hasta a zonas separadas pero contenidas en el mismo hábitat ya que de todos los contrastes de Mann-Whitney realizados, sólo los índices ADI y AEI han determinado que los resultados entre dos grabadoras del hábitat vera pertenecen a una misma población. El resto de las combinaciones en vera o de los índices ADI y AEI en matorral han determinado que, ambas muestras no pertenecen a la misma población. Esto podría indicar que los dos resultados diferentes se pueden deber a los datos que fueron tomados.

El estudio temporal de los índices acústicos ha demostrado que los modelos que incluían la fecha de muestreo eran los que tenían mejor resultado. Han excepción una vez más los índices ACI y AEI, lo que nos indica que efectivamente estos dos índices

han tenido un comportamiento muy distinto al de los demás sobre los datos que hemos utilizado. Los factores aleatorios utilizados en estos modelos mixtos han sido el número de grabadora y el tiempo. Utilizándolos hemos visto que el modelo se ajusta mejor a la complejidad de los datos que intentando predecir únicamente con el hábitat como variable predictora.

La conclusión sobre la evolución de estos modelos en los meses donde se han obtenido datos es que, los índices ACI, AEI y BIO muestran una subida en primavera de la diversidad seguida por una bajada en verano que se va recuperando durante el otoño. Sin embargo, los índices ADI, H y Ht muestran que el momento de más diversidad se da al entrar en el otoño. Por último, el índice NDSI es el que más diferencia ha mostrado con respecto a los demás indicando un declive significativo a medida que avanzan los meses.

Como ampliación al estudio temporal, se ha realizado la modelización ARIMA en los dos hábitats usando los datos del índice BIO ya que da buenos resultados y es uno de los más utilizados en los trabajos relacionados con la diversidad. Este análisis profundo sobre las series temporales creadas, ha dado como resultado dos modelos de ARIMA, uno para cada hábitat. El del hábitat matorral se ha podido construir en base a una serie estacionaria mientras que el del hábitat vera se ha construido en base a una serie no estacionaria. En ambos casos se ha comprobado que los coeficientes de los modelos son significativos pero también se ha visto que los residuos de estos modelos no tienen autocorrelación aunque no siguen una distribución normal.

## 5.1 Líneas futuras

Un estudio como este presenta líneas futuras muy diversas.

La más urgente sería aumentar el número de datos sobre los que se hace el estudio. Por una parte, se podrían obtener grabaciones de más puntos en estos ecosistemas y de nuevos puntos que estén localizados en los otros tres ecosistemas contenidos en Doñana. Por otro lado, se podrían utilizar datos grabados en invierno para hacer una comparación entre todas las estaciones y como análisis comparativo lo mejor sería obtener datos grabados de años distintos para poder entender qué características se han producido en cada año.

Además, se podría continuar el estudio de estacionalidad midiendo los ACF y PACF de grabaciones que estén separadas con menos de media hora y más de 10 minutos

para intentar optimizar el tiempo entre cada grabación que muestra la menor autocorrelación posible.

Con respecto a los modelos mixtos, se podrían crear otras variables aleatorias con las que ajustar mejor el modelo a los datos para que trabaje todavía mejor su complejidad.

En cuanto a los modelos ARIMA obtenidos, también se puede replicar estos modelos en otros de los índices que sean interesantes para contrastar el comportamiento de cada uno y poder hacer predicciones.

Para verificar los resultados de estos índices acústicos, se podría hacer un estudio de comparación con métricas de diversidad tomadas de las grabaciones por expertos. Este tipo de estudios se han realizado en varios lugares del mundo, pero dependiendo del ambiente unos índices funcionan mejor que otros, por lo que sería de utilidad hacer la comparación para determinar qué índices son realmente mejores en Doñana.

Gracias a la PAM, podemos utilizar el cálculo de estos índices y los estudios estadísticos para determinar la evolución de la diversidad en un lugar como Doñana sin la necesidad de tener a un experto etiquetando grabaciones, lo cual es un trabajo muy costoso y extenso. Este estudio de estos índices y sus resultados siempre se puede ampliar ya que se pueden obtener más datos y se pueden probar índices diferentes. Este campo de la ecoacústica está en plena fase de desarrollo, lo que permite investigar muchas opciones distintas buscando siempre ayudar a un lugar tan importante y necesitado como es Doñana.

## 6. REFERENCIAS

Alcocer, I., Lima, H., Sugai, L. S. M., & Llusia, D. (2022). Acoustic indices as proxies for biodiversity: A meta-analysis. *Biological Reviews*, 97(6), 2209-2236.  
<https://doi.org/10.1111/bry.12890>

Anchuelo, Á. (1993). *Series integradas y cointegradas: Una introducción*.

Andrews, C., & Dick, J. (2021, octubre 16). *The potential use of acoustic indices for biodiversity monitoring at long-term ecological research (LTER) sites: A summary of current knowledge, equipment and methods* [Publication - Report]. UK Centre for Ecology & Hydrology. <https://nora.nerc.ac.uk/id/eprint/531301/>

Bates, D., Maechler, M., Bolker [aut, B., cre, Walker, S., Christensen, R. H. B., Singmann, H., Dai, B., Scheipl, F., Grothendieck, G., Green, P., Fox, J., Bauer, A.,

- simulate.formula), P. N. K. (shared copyright on, Tanaka, E., & Jagan, M. (2024). *lme4: Linear Mixed-Effects Models using «Eigen» and S4* (1.1-35.3) [Software]. <https://cran.r-project.org/web/packages/lme4/index.html>
- Bevans, R. (2020, marzo 26). *Akaike Information Criterion | When & How to Use It (Example)*. Scribbr. <https://www.scribbr.com/statistics/akaike-information-criterion/>
- Boelman, N. T., Asner, G. P., Hart, P. J., & Martin, R. E. (2007). Multi-trophic invasion resistance in Hawaii: Bioacoustics, field surveys, and airborne remote sensing. *Ecological Applications*, 17(8), 2137-2144. <https://doi.org/10.1890/07-0004.1>
- Buxton, R. T., McKenna, M. F., Clapp, M., Meyer, E., Stabenau, E., Angeloni, L. M., Crooks, K., & Wittemyer, G. (2018). Efficacy of extracting indices from large-scale acoustic recordings to monitor biodiversity. *Conservation Biology*, 32(5), 1174-1184. <https://doi.org/10.1111/cobi.13119>
- C. Fein, E., Gilmour, J., Machin, T., & Henry, L. (2022). *Statistics for research students*. UNIVERSITY OF SOUTHERN QUEENSLAND TOOWOOMBA.
- Create Elegant Data Visualisations Using the Grammar of Graphics*. (s. f.). Recuperado 4 de junio de 2024, de <https://ggplot2.tidyverse.org/>
- Gaspar, L. P., D. A. Scarpelli, M., Oliveira, E. G., Alves, R. S.-C., Gomes, A. M., Wolf, R., Ferneda, R. V., Kamazuka, S. H., Gussoni, C. O. A., & Ribeiro, M. C. (2023). Predicting bird diversity through acoustic indices within the Atlantic Forest biodiversity hotspot. *Frontiers in Remote Sensing*, 4. <https://www.frontiersin.org/articles/10.3389/frsen.2023.1283719>
- Kasten, E. P., Gage, S. H., Fox, J., & Joo, W. (2012). The remote environmental assessment laboratory's acoustic library: An archive for studying soundscape ecology. *Ecological Informatics*, 12, 50-67. <https://doi.org/10.1016/j.ecoinf.2012.08.001>
- Pieretti, N., Farina, A., & Morri, D. (2011). A new methodology to infer the singing activity of an avian community: The Acoustic Complexity Index (ACI). *Ecological Indicators*, 11(3), 868-873. <https://doi.org/10.1016/j.ecolind.2010.11.005>
- R: *The R Project for Statistical Computing*. (s. f.). Recuperado 30 de mayo de 2024, de <https://www.r-project.org/>
- R: *The R Stats Package*. (s. f.). Recuperado 4 de junio de 2024, de <https://stat.ethz.ch/R-manual/R-devel/library/stats/html/00Index.html>
- Soundscape Ecology: The Science of Sound in the Landscape* | BioScience | Oxford Academic. (s. f.). Recuperado 6 de junio de 2024, de

<https://academic.oup.com/bioscience/article/61/3/203/238162>

Sueur, J., Aubin, T., & Simonis, C. (s. f.). *Sound analysis and synthesis with the package Seewave*.

Sueur, J., Farina, A., Gasc, A., Pieretti, N., & Pavoine, S. (2014). Acoustic Indices for Biodiversity Assessment and Landscape Investigation. *Acta Acustica united with Acustica*, 100(4), 772-781. <https://doi.org/10.3813/AAA.918757>

Thulin, M. (2021). *Modern statistics with R*.

Trigás Gallego, M. (2012). *Metodología Scrum*.

<https://openaccess.uoc.edu/handle/10609/17885>

Vázquez, O. N. T. (2022). Eco-acústica para la conservación. *Eco Solar*, 79, Article 79.

Vicente Vírseda, J. A., González Arias, J., Parra Rodriguez, F. J., & Beltrán Pascual, M. (2019). *Métodos de data science aplicados a la economía y a la administración y dirección de empresas*.

Villanueva-Rivera, L. J., Pijanowski, B. C., Doucette, J., & Pekin, B. (2011). A primer of acoustic analysis for landscape ecologists. *Landscape Ecology*, 26(9), 1233-1246.

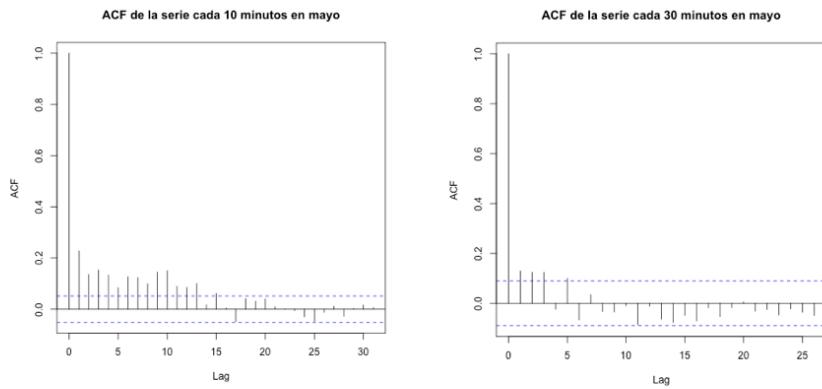
<https://doi.org/10.1007/s10980-011-9636-9>

Yakubu, U. A., & Saputra, M. P. A. (2022). Time Series Model Analysis Using Autocorrelation Function (ACF) and Partial Autocorrelation Function (PACF) for E-wallet Transactions during a Pandemic. *International Journal of Global Operations Research*, 3(3), Article 3. <https://doi.org/10.47194/ijgor.v3i3.168>

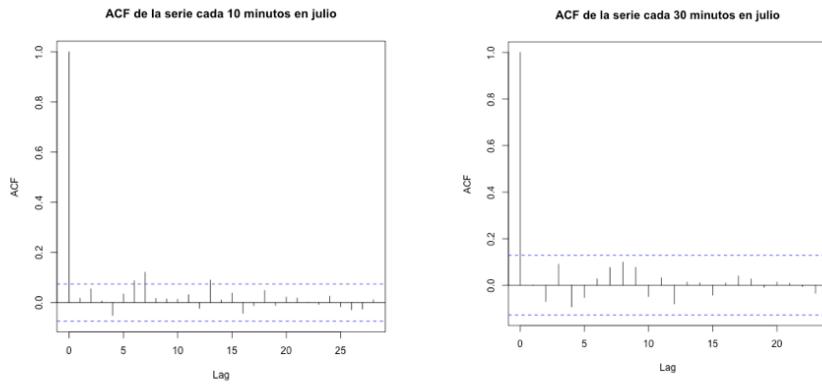
## ANEXOS

### Valores ACF

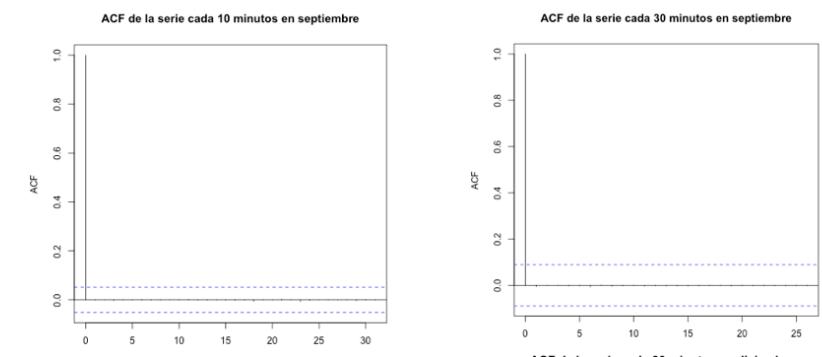
Mayo



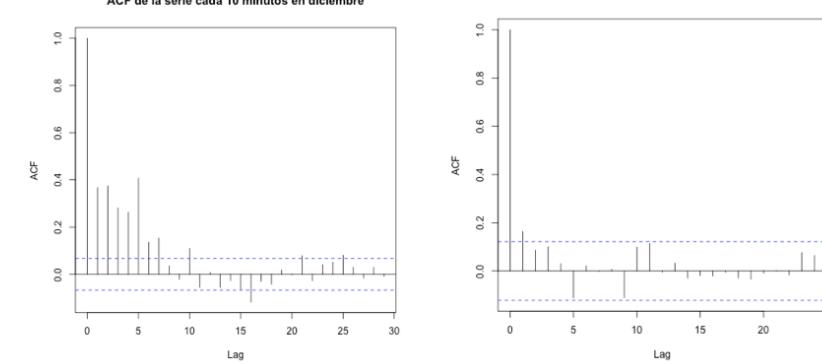
Julio



Septiembre

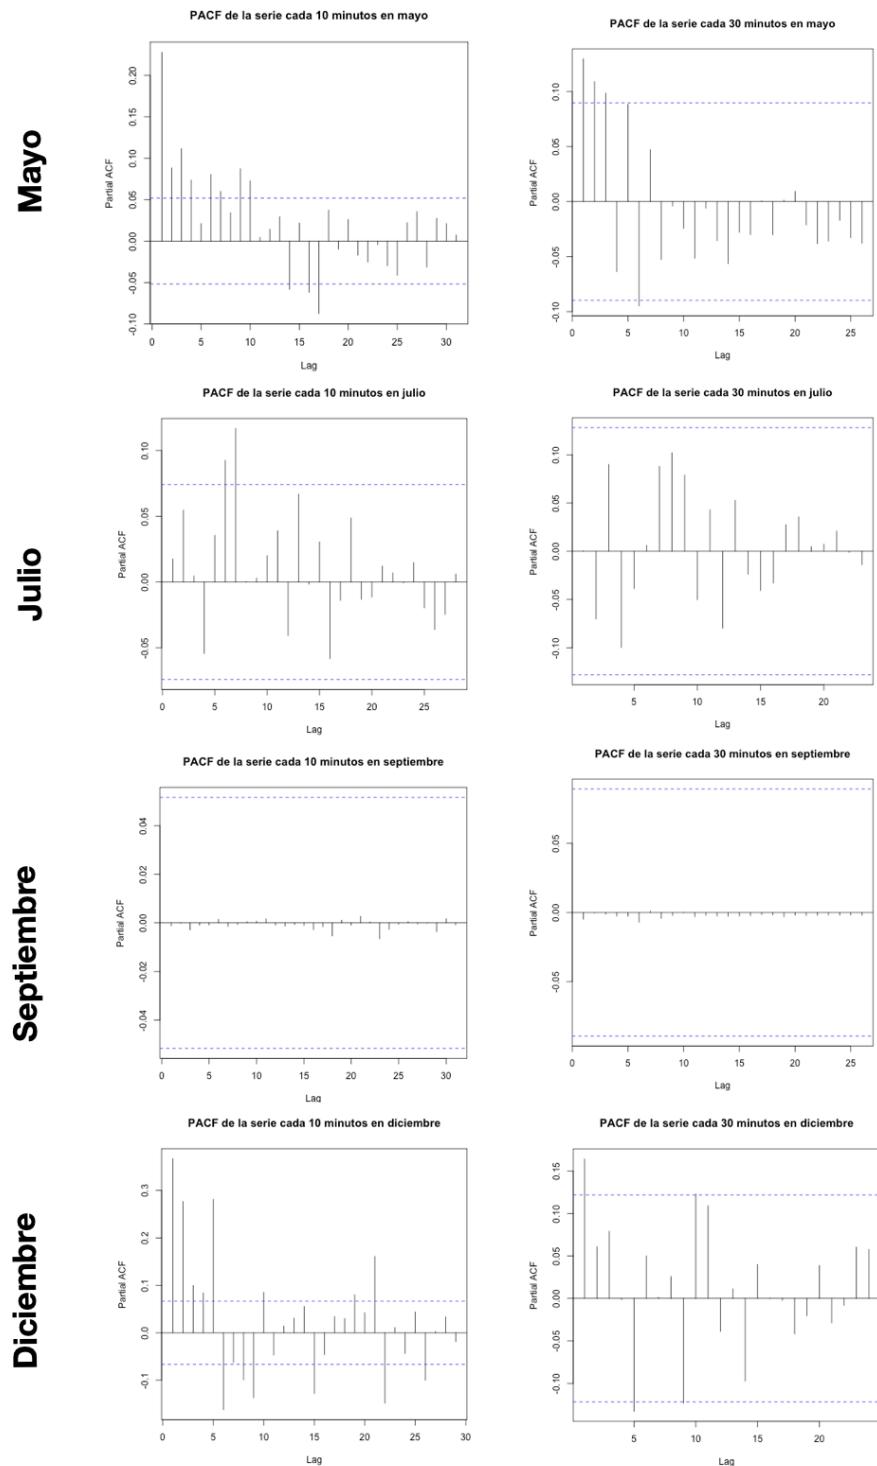


Diciembre



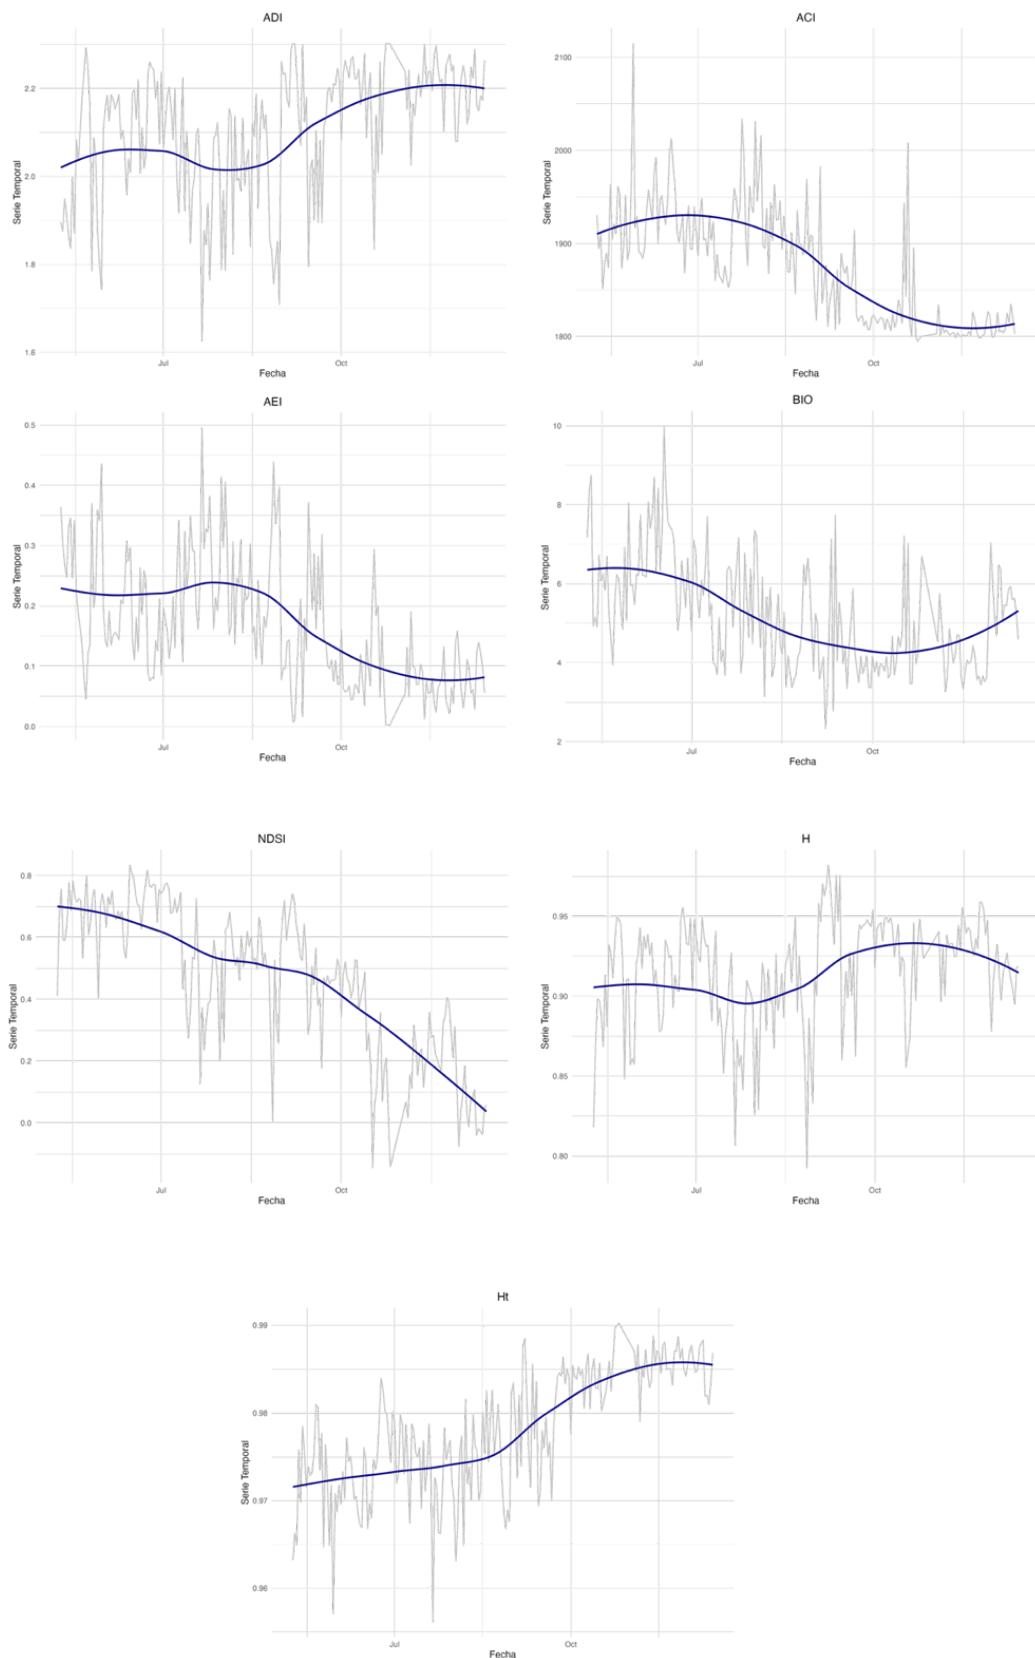
Anexo 1: Gráficos de las funciones ACF

## Valores PACF



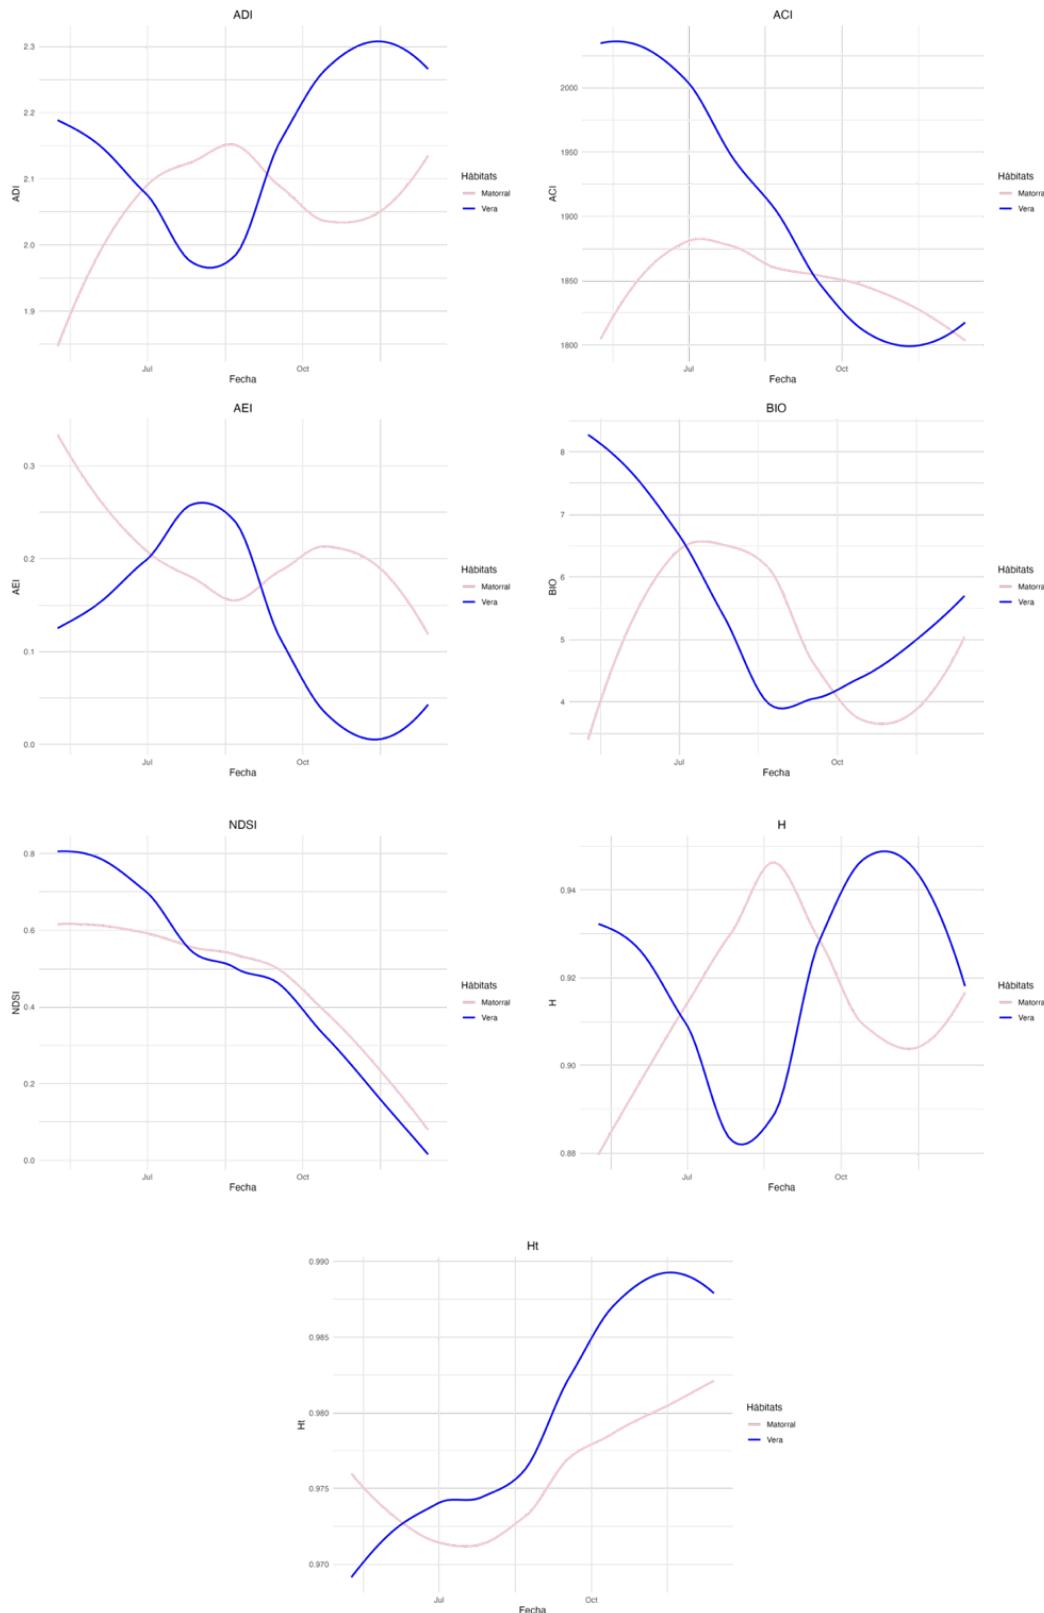
Anexo 2: Gráficos de funciones PACF

## Evolución temporal de los índices globales



Anexo 3: Series temporales de índices acústicos globales

## Evolución temporal de los índices en cada hábitat



*Anexo 4: Series temporales de los índices en cada hábitat.*

